

TD Séance 5 : L'IA qui Doute

Exercices Progressifs — Probabilités et Inférence Bayésienne

Feuille d'énoncés

Dr. El Hadji Bassirou TOURÉ
Département de Mathématiques et Informatique
Faculté des Sciences et Techniques
Université Cheikh Anta Diop de Dakar

M1 IABD — Semestre 1

Organisation de ce TD

Ce TD est conçu pour une **compréhension progressive** du raisonnement probabiliste et de l'inférence bayésienne :

- **Niveau 1** (Ex. 1–2) : Vocabulaire probabiliste, axiomes, distribution jointe
- **Niveau 2** (Ex. 3–5) : Marginalisation, probabilité conditionnelle, théorème de Bayes
- **Niveau 3** (Ex. 6–8) : Importance du prior, mise à jour séquentielle, preuve contradictoire
- **Niveau 4** (Ex. 9–10) : Réseaux bayésiens, d-séparation, Naive Bayes

Conseil : Pour chaque calcul bayésien, suivez la recette en 4 étapes : numérateurs, évidence, division, vérification.

Tous les exercices utilisent le scénario suivant :

Scénario : L’usine de mangues “Casamance Export” à Ziguinchor

Ibrahima est responsable qualité dans une usine de transformation de mangues destinées à l’exportation. Chaque mangue arrivant sur la chaîne de production doit être classée dans l’une de trois catégories :

- **Parfaite (P)** : mangue exportable en l’état
- **Défaut mineur (D)** : vendable au marché local à prix réduit
- **Rejet (R)** : impropre à la consommation, compostée

La base de données historique de l’usine (10 000 mangues inspectées en 2024) donne les proportions suivantes :

Catégorie	Parfaite (P)	Défaut mineur (D)	Rejet (R)
Proportion	60%	25%	15%

Ibrahima observe trois indicateurs pour chaque mangue :

- **Couleur (C)** : uniforme (bon signe) ou tachée (mauvais signe)
- **Texture (T)** : ferme (bon signe) ou molle (mauvais signe)
- **Calibre (K)** : standard (bon signe) ou hors-norme (mauvais signe)

Les données historiques donnent les **vraisemblances** suivantes :

Indicateur défavorable	$P(\cdot \mid \text{Parfaite})$	$P(\cdot \mid \text{Défaut})$	$P(\cdot \mid \text{Rejet})$
Couleur tachée	0,10	0,60	0,90
Texture molle	0,05	0,40	0,80
Calibre hors-norme	0,08	0,35	0,50

Lecture : “Parmi les mangues parfaites, 10% ont une couleur tachée.” “Parmi les rejets, 90% ont une couleur tachée.”

Niveau 1 — Fondations Probabilistes

Exercice 1 : Formaliser l'espace probabiliste

Énoncé

En utilisant le scénario de l'usine de mangues :

1. Quel est l'**univers** Ω pour la variable "Qualité" Q ? Listez les résultats possibles.
2. Écrivez la **distribution de probabilité** $P(Q)$. Vérifiez que les trois axiomes de Kolmogorov sont satisfaits.
3. Calculez $P(Q \neq \text{Parfaite})$, c'est-à-dire la probabilité qu'une mangue ait un problème.
4. Si l'usine traite 500 mangues par jour, combien de rejets Ibrahima doit-il s'attendre à trouver en moyenne ?
5. On définit l'événement $A = \{\text{Parfaite}, \text{Défaut}\}$ ("mangue vendable"). Calculez $P(A)$.

Votre réponse :

Exercice 2 : Construire la distribution jointe**Énoncé**

On s'intéresse à deux variables : la qualité Q et la couleur C (tachée ou uniforme).

1. En utilisant la règle du produit $P(Q, C) = P(C | Q) \times P(Q)$, remplissez le tableau de la distribution jointe ci-dessous.
2. Vérifiez que la somme de toutes les cases vaut 1.
3. Que représente **physiquement** la case $P(\text{Parfaite}, \text{tachée}) = ?$
4. Quelle case du tableau est la plus grande ? Que signifie-t-elle concrètement ?

Méthode : construire une distribution jointe

Pour remplir chaque case du tableau, on utilise la **règle du produit** :

$$P(Q = q, C = c) = P(C = c | Q = q) \times P(Q = q)$$

Exemple : $P(\text{Parfaite}, \text{tachée}) = P(\text{tachée} | \text{Parfaite}) \times P(\text{Parfaite}) = \dots$

On remplit case par case, puis on vérifie que le total fait 1.

Distribution jointe $P(Q, C)$ à compléter :

	$C = \text{tachée}$	$C = \text{uniforme}$	Total ligne
$Q = \text{Parfaite}$			
$Q = \text{Défaut}$			
$Q = \text{Rejet}$			
Total colonne			

Votre réponse :

Niveau 2 — Marginalisation, Conditionnelle et Bayes

Méthode pour tous les exercices de ce niveau

Trois opérations fondamentales sur le tableau de la jointe :

- **Marginalisation** : Sommer une ligne (ou colonne) pour “éliminer” une variable

$$P(Q = q) = \sum_c P(Q = q, C = c) \quad (\text{somme des lignes})$$

- **Conditionnement** : “Zoomer” sur une colonne et renormaliser

$$P(Q = q \mid C = c) = \frac{P(Q = q, C = c)}{P(C = c)}$$

- **Bayes** : Inverser le sens du conditionnement

$$P(Q \mid C) = \frac{P(C \mid Q) \times P(Q)}{P(C)}$$

Exercice 3 : Marginalisation — faire disparaître une variable

Énoncé

À partir du tableau de la distribution jointe complété à l’exercice 2 :

1. **Retrouvez** $P(Q)$ en sommant les lignes du tableau. Comparez avec les données initiales du scénario.
2. **Calculez** $P(C)$ en sommant les colonnes du tableau.
 - Quelle est la proportion globale de manges tachées dans l’usine ?
 - Ce chiffre est-il directement donné dans l’énoncé ? D’où vient-il ?
3. Imaginez qu’Ibrahima ferme les yeux et pioche une mangue au hasard. Quelle est la probabilité qu’elle soit tachée ? Justifiez en utilisant la formule des probabilités totales.

Marginalisation sur les lignes (retrouver $P(Q)$) :

Q	$P(Q, \text{tachée})$	$+ P(Q, \text{uniforme})$	$= P(Q)$
Parfaite			
Défaut			
Rejet			

Marginalisation sur les colonnes (calculer $P(C)$) :

C	$P(\text{Parfaite}, C)$	$+ P(\text{Défaut}, C)$	$+ P(\text{Rejet}, C)$	$= P(C)$
tachée				
uniforme				

Votre réponse :

Exercice 4 : Probabilité conditionnelle — le “zoom”**Énoncé**

Ibrahima observe qu'une mangue a la couleur **tachée**. Il veut savoir : “*sachant qu'elle est tachée, quelle est la probabilité que ce soit un rejet ?*”

1. En utilisant **uniquement le tableau de la jointe**, calculez :
 - $P(\text{Parfaite} \mid \text{tachée})$
 - $P(\text{Défaut} \mid \text{tachée})$
 - $P(\text{Rejet} \mid \text{tachée})$
2. Vérifiez que ces trois probabilités conditionnelles somment à 1.
3. Comparez le prior $P(Q)$ avec le posterior $P(Q \mid \text{tachée})$ dans le tableau ci-dessous. Pour chaque catégorie, la probabilité a-t-elle augmenté ou diminué ? Pourquoi ?
4. Expliquez avec vos mots le “zoom” : pourquoi divise-t-on par $P(\text{tachée})$?

Calcul de $P(Q \mid \text{tachée})$ par la formule $P(Q \mid C) = P(Q, C)/P(C)$:

Q	$P(Q, \text{tachée})$	$\div P(\text{tachée})$	$= P(Q \mid \text{tachée})$
Parfaite		$\div$	
Défaut		$\div$	
Rejet		$\div$	
Vérification : total			

Comparaison avant/après observation :

Q	Prior $P(Q)$	$\xrightarrow{\text{tachée}}$ Posterior $P(Q \mid \text{tachée})$	$\uparrow$ ou $\downarrow$?
Parfaite	0,60		
Défaut	0,25		
Rejet	0,15		

Votre réponse :

Exercice 5 : Le théorème de Bayes — inverser le raisonnement**Énoncé**

Refaites le calcul de l'exercice 4, mais cette fois **en utilisant la formule de Bayes** plutôt que le tableau de la jointe.

Données : On observe une mangue **tachée**. Calculer $P(Q \mid \text{tachée})$ pour chaque catégorie.

1. **Étape 1 :** Calculez le **numérateur** de Bayes pour chaque hypothèse : $\text{Num}(q) = P(\text{tachée} \mid Q = q) \times P(Q = q)$
2. **Étape 2 :** Calculez l'**évidence** $P(\text{tachée})$ comme somme des numérateurs.
3. **Étape 3 :** Divisez chaque numérateur par l'évidence pour obtenir le posterior.
4. **Étape 4 :** Vérifiez que les posteriors somment à 1.
5. Retrouvez-vous les mêmes résultats qu'à l'exercice 4 ? Est-ce normal ?

Recette de Bayes en 4 étapes

$$P(H \mid E) = \frac{P(E \mid H) \times P(H)}{P(E)}$$

1. **Numérateur :** $P(E \mid H) \times P(H)$ pour chaque hypothèse H
2. **Évidence :** $P(E) = \sum_h P(E \mid H = h) \times P(H = h)$ (somme des numérateurs)
3. **Division :** $P(H \mid E) = \text{Num}(H) / P(E)$
4. **Vérification :** $\sum_h P(H = h \mid E) = 1$

Tableau de Bayes à compléter :

Q	Prior $P(Q)$	Vraisembl. $P(\text{tachée} \mid Q)$	Numérateur	Posterior
Parfaite	0,60	0,10		
Défaut	0,25	0,60		
Rejet	0,15	0,90		
Somme (= Évidence $P(\text{tachée})$)				

Votre réponse :

Niveau 3 — Prior, Mise à Jour Séquentielle, Preuve Contradictoire

Exercice 6 : L'importance capitale du prior

Énoncé

Même observation, contexte différent. On compare deux usines qui traitent les mêmes variétés de mangues (mêmes vraisemblances) mais avec des **priors différents** :

	Parfaite	Défaut	Rejet
Usine Ziguinchor (bonne récolte)	0,60	0,25	0,15
Usine Tambacounda (récolte médiocre)	0,20	0,35	0,45

Les vraisemblances $P(\text{tachée} | Q)$ restent identiques : 0,10 / 0,60 / 0,90.

1. Appliquez Bayes pour l'usine de Tambacounda avec l'observation "tachée". Remplissez le tableau ci-dessous.
2. Comparez les posteriors des deux usines. Même observation + même vraisemblance = même conclusion ?
3. Expliquez pourquoi le prior fait toute la différence.
4. Calculez le **rapport de vraisemblance** (LR) entre Rejet et Parfaite pour l'observation "tachée". Interprétez.

Bayes pour l'usine de Tambacounda :

Q	Prior (Tamba)	$P(\text{tachée} Q)$	Numérateur	Posterior
Parfaite	0,20	0,10		
Défaut	0,35	0,60		
Rejet	0,45	0,90		
Évidence				

Comparaison des deux usines :

	Ziguinchor $P(Q \text{tachée})$	Tambacounda $P(Q \text{tachée})$
Parfaite		
Défaut		
Rejet		

Rapport de vraisemblance $\text{LR}(\text{Rejet vs Parfaite}) = \frac{P(\text{tachée}|\text{Rejet})}{P(\text{tachée}|\text{Parfaite})} = \underline{\hspace{2cm}}$

Votre réponse :

Exercice 7 : Mise à jour séquentielle — accumuler les preuves**Énoncé**

Ibrahima examine une mangue de l'usine de **Ziguinchor** étape par étape. Il observe successivement trois indicateurs. **Le posterior de chaque étape devient le prior de l'étape suivante.**

1. **Observation 1 : couleur tachée.** Vous l'avez déjà calculé (Ex. 5). Recopiez les posteriors.
2. **Observation 2 : texture molle.** En prenant les posteriors de l'étape 1 comme nouveaux priors, appliquez Bayes avec les vraisemblances de la texture.
3. **Observation 3 : calibre hors-norme.** Appliquez Bayes une troisième fois.
4. Remplissez le tableau récapitulatif montrant l'évolution des croyances.
5. Quelle est la décision d'Ibrahima à la fin des trois observations ?

Étape 2 : mise à jour avec la texture (molle). Nouveau prior = posterior de l'étape 1.

Q	Prior (= post. étape 1)	$P(\text{molle} \mid Q)$	Num.	Posterior
Parfaite		0,05		
Défaut		0,40		
Rejet		0,80		
Évidence				

Étape 3 : mise à jour avec le calibre (hors-norme). Nouveau prior = posterior de l'étape 2.

Q	Prior (= post. étape 2)	$P(\text{hors-norme} \mid Q)$	Num.	Posterior
Parfaite		0,08		
Défaut		0,35		
Rejet		0,50		
Évidence				

Tableau récapitulatif — évolution des croyances :

Q	Prior initial	+Tachée	+Molle	+Hors-norme
Parfaite	60,0%	%	%	%
Défaut	25,0%	%	%	%
Rejet	15,0%	%	%	%

Décision d'Ibrahima : _____

Exercice 8 : Quand la preuve contredit**Énoncé**

Ibrahima examine une autre mangue. Les deux premières observations convergent vers un rejet : couleur tachée puis texture molle (posteriors de l'exercice 7, étape 2). Mais la troisième observation est **surprenante** :

Observation 3 (alternative) : calibre standard (au lieu de hors-norme).

1. Calculez $P(\text{standard} \mid Q)$ pour chaque catégorie (complémentaire de “hors-norme”).
2. Appliquez Bayes avec les posteriors de l'étape 2 comme priors.
3. La probabilité de Rejet a-t-elle augmenté ou diminué ? De combien ?
4. Comparez avec l'exercice 7 (calibre hors-norme). Comment la direction de la preuve affecte-t-elle le raisonnement ?
5. Ibrahima doit-il quand même rejeter cette mangue ? Justifiez.

Vraisemblances pour “calibre standard” (complémentaire) :

Q	$P(\text{hors-norme} \mid Q)$	$P(\text{standard} \mid Q) = 1 - \dots$
Parfaite	0,08	
Défaut	0,35	
Rejet	0,50	

Bayes avec calibre standard :

Q	Prior (= post. étape 2)	$P(\text{standard} \mid Q)$	Num.	Posterior
Parfaite				
Défaut				
Rejet				
Évidence				

Comparaison : preuve convergente vs contradictoire

Q	Après étape 2	+Hors-norme (Ex. 7)	+Standard (Ex. 8)
Parfaite			
Défaut			
Rejet			

Votre réponse :

Niveau 4 — Réseaux Bayésiens et Classification

Exercice 9 : Construire un réseau bayésien

Énoncé

L'usine veut modéliser les relations entre toutes les variables pertinentes. En plus de Q , C , T , K , on ajoute :


- **Saison (S)** : saison sèche ou hivernage (influence la qualité des mangues)
- **Variété (V)** : Kent ou Keitt (influence la qualité)

1. Dessinez le réseau bayésien (DAG) avec les 6 variables. Les arcs représentent des influences causales directes. Justifiez chaque arc.
2. Écrivez la **factorisation** de la distribution jointe selon le réseau :

$$P(S, V, Q, C, T, K) = \dots$$

3. **Comptez les paramètres** du réseau (toutes les variables sont binaires) et comparez avec la jointe brute ($2^6 - 1$).
4. Identifiez les **trois structures canoniques** dans votre réseau :
 - Une **chaîne** : $X \rightarrow Y \rightarrow Z$
 - Une **cause commune** : $X \leftarrow Y \rightarrow Z$
 - Une **v-structure** : $X \rightarrow Y \leftarrow Z$
5. Pour chaque structure identifiée, répondez : X et Z sont-ils indépendants ? Et si on observe Y ?

Réseau bayésien (dessinez les nœuds et les arcs) :



(Tracez les flèches sur les lignes pointillées pour indiquer le sens causal)

Factorisation : $P(S, V, Q, C, T, K) =$ _____

Comptage des paramètres :

Variable	Parents	Nb de paramètres
S		
V		
Q		
C		
T		
K		
Total réseau		
Jointe brute $2^6 - 1$		63

Structures canoniques et d-séparation :

Structure	Triplet X, Y, Z	$X \perp Z ?$	$X \perp Z \mid Y ?$	Obs. Y : bloque/ouvre ?
Chaîne				
Cause commune				
V-structure				

Votre réponse :

Exercice 10 : Inférence par énumération et Naive Bayes**Énoncé****Partie A — Inférence par énumération.**

Calculez $P(Q \mid C = \text{tachée}, T = \text{molle})$ directement par la factorisation du réseau $C \leftarrow Q \rightarrow T$ (sans variables Saison/Variété).

1. Écrivez la jointe factorisée : $P(Q, C, T) = P(Q) \cdot P(C \mid Q) \cdot P(T \mid Q)$.
2. Évaluez pour chaque valeur de Q avec $C = \text{tachée}$ et $T = \text{molle}$.
3. Normalisez.
4. Comparez avec le résultat de l'exercice 7 (étape 2). Trouvez-vous la même chose ?

Partie B — Naive Bayes : pont vers le Machine Learning.

Ibrahima veut automatiser le tri. Il dispose d'un historique de 10 000 mangues classées manuellement. Il construit un classificateur **Naive Bayes** qui prédit la catégorie à partir des trois indicateurs.

5. Écrivez la formule du classificateur Naive Bayes :

$$P(Q \mid C, T, K) \propto ?$$

6. Une nouvelle mangue arrive avec : tachée, ferme, standard. Classifiez-la.
7. Comparez avec la mangue de l'exercice 7 (tachée, molle, hors-norme).
8. Pourquoi ce classificateur s'appelle-t-il "naïf" ? Quelle hypothèse fait-il ?
9. **Lien avec le ML** : Que faudrait-il changer si les vraisemblances n'étaient *pas* données par l'expert mais devaient être *appries* à partir des données ?

Partie A — Inférence par énumération :

Q	$P(Q)$	$P(\text{tachée} \mid Q)$	$P(\text{molle} \mid Q)$	Produit	Normalisé
Parfaite	0,60	0,10	0,05		
Défaut	0,25	0,60	0,40		
Rejet	0,15	0,90	0,80		
Somme					

Partie B — Naive Bayes avec (tachée, ferme, standard) :

Q	$P(Q)$	$P(\text{tachée} \mid Q)$	$P(\text{ferme} \mid Q)$	$P(\text{standard} \mid Q)$	Produit	Normalisé
Parfaite	0,60	0,10				
Défaut	0,25	0,60				
Rejet	0,15	0,90				
Somme						

Votre réponse :

Aide-mémoire

Concept	Formule	En français
Complémentaire	$P(\neg A) = 1 - P(A)$	Ce qui ne se produit pas
Distribution jointe	$P(X, Y) = P(Y \mid X) \cdot P(X)$	Probabilité de la combinaison
Marginalisation	$P(X) = \sum_y P(X, Y = y)$	Sommer pour éliminer Y
Conditionnelle	$P(X \mid Y) = \frac{P(X, Y)}{P(Y)}$	Zoomer sur $Y = y$, renormaliser
Bayes	$P(H \mid E) = \frac{P(E \mid H) \cdot P(H)}{P(E)}$	Posterior $\propto$ Vraisemblance $\times$ Prior
Probabilités totales	$P(E) = \sum_h P(E \mid H = h) \cdot P(H = h)$	L'évidence = somme des numérateurs
Indépendance	$P(X, Y) = P(X) \cdot P(Y)$	Connaître l'un n'aide pas pour l'autre
Réseau bayésien	$P(X_1, \dots, X_n) = \prod_i P(X_i \mid \text{Pa}(X_i))$	La jointe = produit des CPTs

Structure canonique	Sans observer B	En observant B	Mnémonique
Chaîne $A \rightarrow B \rightarrow C$	A, C dépendants	$A \perp C \mid B$	<i>Observer bloque</i>
Cause commune $A \leftarrow B \rightarrow C$	A, C dépendants	$A \perp C \mid B$	<i>Observer bloque</i>
V-structure $A \rightarrow B \leftarrow C$	$A \perp C$	A, C dépendants	<i>Observer ouvre !</i>

Erreur classique à éviter

$$P(A \mid B) \neq P(B \mid A)$$

“90% des rejets sont tachés” $\neq$ “90% des mangues tachées sont des rejets”

C'est l'**erreur du procureur**. Toujours utiliser Bayes pour inverser le conditionnement.