



Introduction au Machine Learning

# Séance 4 — Des données propres : préparer avant d'apprendre

**Dr. El Hadji Bassirou TOURÉ**

Département de Mathématiques et Informatique, Faculté des Sciences et Techniques, Université Cheikh Anta Diop de Dakar

---

<https://elbachir67.github.io/cours/introduction-machine-learning/chapitres/04-donnees-propres.html>

Version du 26 septembre 2026



Version en ligne

# Introduction au ML — Séance 4

Des données propres : préparer avant d'apprendre

Dr. El Hadji Bassirou TOURÉ

Département de Mathématiques et Informatique, Faculté des Sciences et Techniques, Université Cheikh Anta Diop de Dakar

# Objectifs de la séance

## Contenu

La Séance 3 a entraîné un arbre sur des données impeccables. Cette séance affronte les **données réelles** — trouées, hétérogènes, piégées — sur un vrai jeu médical (Pima), et construit la chaîne de préparation rigoureuse qui rend un modèle digne de confiance.

- Détecter et **réparer les valeurs manquantes** : taux de manquants, imputation par la médiane.
- **Encoder** les catégories (one-hot) et **mettre à l'échelle** les variables (z-score).
- Un second modèle, les  $k$  **plus proches voisins** — pour qui l'échelle est une condition de validité.
- Le danger central du métier : la **fuite de données** — et le **Pipeline** qui l'empêche,  
 $f = m \circ \varphi$ .

# Des données réelles, enfin

# Le réveil brutal

## Changement de décor


DataSANTÉ-221 était un registre impeccable : aucune case vide, des échelles raisonnables. Les données réelles ne ressemblent jamais à cela. Cette séance travaille sur **Pima** — une vraie étude médicale : 768 patientes, 8 mesures cliniques, et une cible : le **diabète** (268 positives, 500 négatives).

## Les trois premières patientes — extrait

| patiente | glycémie | pression | insuline | IMC  | âge | diabète   |
|----------|----------|----------|----------|------|-----|-----------|
| $x_1$    | 148      | 72       | 0        | 33,6 | 50  | $y_1 = 1$ |
| $x_2$    | 85       | 66       | 0        | 26,6 | 31  | $y_2 = 0$ |
| $x_3$    | 183      | 64       | 0        | 23,3 | 32  | $y_3 = 1$ |

Une ligne par patiente, comme toujours. Mais un détail cloche déjà : trois insulines à 0...

# Le problème caché : des zéros impossibles



Une glycémie de 0 ou une pression artérielle de 0 sont *physiologiquement impossibles* : ce ne sont pas des mesures, ce sont des **absences de mesure** codées par un 0. Près d'une patiente sur deux n'a pas de dosage d'insuline (374/768). Le fichier ne ment pas — il *cache* ses trous.

# La valeur manquante, formellement

## Définition

Une **valeur manquante** est une case du tableau pour laquelle aucune mesure n'existe. Elle se note **NaN** (*Not a Number*) — jamais 0, qui est une valeur comme une autre. Le **taux de manquants** d'une colonne mesure l'ampleur du trou.

$$m_j = \frac{1}{n} \sum_{i=1}^n \mathbf{1}[x_{ij} \text{ manquant}]$$

La somme compte les cases vides de la colonne  $j$  ; la division par  $n$  en donne la proportion — exactement la mécanique du risque empirique de la Séance 3, appliquée aux trous plutôt qu'aux erreurs.

# Exemple — les taux de manquants de Pima

Après remplacement des zéros impossibles par NaN

| colonne   | glycémie | pression | IMC   | pli cutané | insuline     |
|-----------|----------|----------|-------|------------|--------------|
| manquants | 5        | 35       | 11    | 227        | 374          |
| $m_j$     | 0,007    | 0,046    | 0,014 | 0,296      | <b>0,487</b> |

Pour l'insuline :  $m = \frac{374}{768} = 0,487$  — près d'une case sur deux.

Cinq colonnes touchées, à des degrés très différents : la réparation devra être *automatique et colonne par colonne*.

# Exercice — calculer un taux de manquants

## Énoncé

La colonne pression compte 35 valeurs manquantes sur 768 patientes. **(a)** Calculer  $m_{\text{pression}}$ .  
**(b)** Si l'on jetait toute ligne ayant *au moins un* trou, il resterait 392 patientes : quelle proportion du jeu perdrait-on ?

## Correction

**(a)**  $m = \frac{35}{768} = 0,046$ , soit 4,6 %. **(b)** On perdrait  $768 - 392 = 376$  patientes, soit  $\frac{376}{768} = 49\%$  du jeu — la moitié des données sacrifiée pour des trous réparables.

# Piège — entraîner sur les zéros tels quels

## Erreur fréquente

Laisser les zéros impossibles dans les données. Le modèle apprend alors qu'il existe des patientes « à glycémie nulle » — une population fantôme — et place des coupures absurdes autour de 0. Le score peut même sembler correct : le poison est *silencieux*.

## Erreur fréquente — bis

Jeter toutes les lignes incomplètes : ici, 49 % des patientes disparaîtraient. Pire, elles ne disparaissent pas *au hasard* — les patientes sans dosage d'insuline sont souvent celles des structures les moins équipées : on biaiserait l'échantillon en croyant le nettoyer.

La voie raisonnable : **garder les lignes, remplir les trous**. C'est l'imputation.

# Réparer : l'imputation par la médiane

# L'idée : remplir avec une valeur plausible

## Le principe

**Imputer**, c'est remplacer chaque case vide d'une colonne par une valeur *typique* de cette colonne. La question devient : quelle valeur typique ? La moyenne semble naturelle — mais elle a un défaut rédhibitoire sur les données médicales.

## Analogie

Pour estimer le loyer « typique » d'un quartier, la moyenne se laisse entraîner par une seule villa de luxe ; le loyer *médian* — celui du logement du milieu — reste fidèle au quartier. Les colonnes médicales ont leurs villas de luxe : les valeurs extrêmes.

# La médiane, formellement


## Définition

La **médiane** d'une colonne est la valeur du *milieu* une fois les valeurs triées : la moitié des valeurs lui est inférieure, la moitié supérieure. Contrairement à la moyenne, elle est **robuste** : une valeur extrême ne la déplace presque pas.

## Exemple numérique — cinq insulines

Valeurs triées : 88 ; 94 ; **105** ; 130 ; 480. La médiane est la 3<sup>e</sup> valeur : **105**. La moyenne, elle, vaut  $\frac{88 + 94 + 105 + 130 + 480}{5} = 179,4$  — tirée vers le haut par la seule valeur 480, au point de dépasser 4 patientes sur 5.

# La robustesse, en image



Quatre patientes entre 88 et 130, une à 480 : la moyenne (179,4) ne ressemble à *aucune* patiente ; la médiane (105) reste au cœur du groupe. C'est elle qu'on injecte dans les trous.

# L'imputation, formellement

## Définition

L'**imputation par la médiane** remplace chaque valeur manquante de la colonne  $j$  par la médiane  $\text{med}_j$  de cette colonne — médiane calculée sur le **jeu d'entraînement uniquement**.

$$\tilde{x}_{ij} = \begin{cases} x_{ij} & \text{si } x_{ij} \text{ est observée} \\ \text{med}_j & \text{si } x_{ij} \text{ est manquante} \end{cases}$$

Point décisif :  $\text{med}_j$  est un **paramètre appris** des données, au même titre que les coupures de l'arbre. Et comme tout paramètre appris, il s'apprend sur le train — *jamais* sur le test. La raison précise arrive à la section « fuite de données ».

# Exemple — l'imputation en chiffres sur Pima

## Médianes apprises sur le train

Sur les 614 patientes d'entraînement :  $\text{med}_{\text{insuline}} = 125,5$ ,  $\text{med}_{\text{glycémie}} = 118,0$ ,  $\text{med}_{\text{IMC}} = 32,0$ .

La patiente n°525 (du test) a une insuline manquante :  $\tilde{x}_{525, \text{insuline}} = \text{med}_{\text{insuline}} = 125,5$ .  
Ses valeurs observées (glycémie 87, âge 21) restent intactes.

À comparer : la *moyenne* de l'insuline sur le train vaut 139,4 — gonflée par les valeurs extrêmes, elle aurait rempli les trous avec une valeur peu typique.

# Exercice — imputer à la main

## Énoncé

Une mini-colonne IMC contient : 24,1 ; NaN ; 31,5 ; 28,0 ; NaN ; 35,2. **(a)** Calculer la médiane des valeurs observées. **(b)** Donner la colonne imputée.

## Correction

**(a)** Valeurs observées triées : 24,1 ; 28,0 ; 31,5 ; 35,2 — nombre pair, la médiane est la moyenne des deux du milieu :  $\frac{28,0 + 31,5}{2} = 29,75$ . **(b)** Colonne imputée : 24,1 ; **29,75** ; 31,5 ; 28,0 ; **29,75** ; 35,2 — les valeurs observées ne bougent pas.

# En pratique : SimpleImputer

```
import numpy as np
from sklearn.impute import SimpleImputer

X[colonnes_impossibles] = X[colonnes_impossibles].replace(0, np.nan)
imputeur = SimpleImputer(strategy="median")
imputeur.fit(X_train) # apprend les medianes (train !)
X_train_p = imputeur.transform(X_train)
X_test_p = imputeur.transform(X_test) # applique les MEMES medianes
```

Le motif `fit` / `transform` est le cœur de toute la séance : `fit` *apprend* les paramètres (ici, une médiane par colonne), `transform` les *applique*. Le test ne voit jamais `fit` — il ne fait que subir `transform`.

# Encoder les catégories

# Le problème : les modèles mangent des nombres

## Le constat

Distances, seuils, moyennes : tout ce que manipule un modèle est **numérique**. Or les données réelles portent des **catégories** — une région ( $\{\text{Dakar, Thiès, Kaolack, Ziguinchor, Saint-Louis}\}$ ), un sexe, un type d'admission. Il faut les traduire en nombres *sans inventer d'information*.

## Erreur fréquente

Coder Dakar = 1, Thiès = 2, ..., Saint-Louis = 5. Ces entiers fabriquent un **ordre fictif** (Saint-Louis > Dakar ?) et de fausses distances (Kaolack serait « deux fois plus loin » de Dakar que Thiès). Le modèle prendra cette géométrie inventée au sérieux.

# L'encodage one-hot, formellement

## Définition

L'encodage **one-hot** remplace une colonne à  $K$  modalités par  $K$  colonnes binaires : la colonne de la modalité observée vaut 1, toutes les autres 0. Aucun ordre, aucune distance fictive — chaque modalité est à égale distance de toutes les autres.

## Exemple — la région en cinq colonnes

| région          | Dakar | Thiès | Kaolack | Ziguinchor | Saint-Louis |
|-----------------|-------|-------|---------|------------|-------------|
| « Thiès »       | 0     | 1     | 0       | 0          | 0           |
| « Saint-Louis » | 0     | 0     | 0       | 0          | 1           |

Une seule colonne « chaude » (*hot*) par ligne — d'où le nom.

# Exercice — encoder à la main

## Énoncé

Une colonne « type d'admission » a 4 modalités : urgences, consultation, transfert, programmée. **(a)** Combien de colonnes produit le one-hot ? **(b)** Encoder « transfert ». **(c)** Pourquoi ne pas coder simplement 1, 2, 3, 4 ?

## Correction

**(a)** 4 colonnes binaires. **(b)** (0, 0, 1, 0). **(c)** Les entiers imposeraient un ordre et des écarts inventés — « programmée » (4) serait *trois fois plus loin* des urgences (1) que « consultation » (2), une géométrie qui ne correspond à rien de médical et que les distances de la section suivante prendraient au pied de la lettre.

# Mettre à l'échelle : la standardisation

# Le problème des échelles

## Le constat sur Pima

L'âge court de 21 à 81 ; l'insuline de 14 à 846. Les deux colonnes parlent des unités incomparables — et tout calcul qui les *mélange* (une distance, une somme pondérée) sera dominé par la colonne aux grands nombres, indépendamment de son intérêt médical.

## Analogie

Comparer des prix en francs CFA et en euros sans convertir : celui en francs « pèse » des centaines de fois plus dans toute addition — non parce qu'il est plus cher, mais parce que son unité est plus petite. La standardisation est cette conversion : tout le monde dans la même monnaie.

# Le z-score, formellement

## Définition

**Standardiser** une colonne, c'est la recentrer sur 0 et la réduire à un écart-type de 1 : chaque valeur devient son **z-score** — sa distance à la moyenne, *comptée en écarts-types*.

$$z = \frac{x - \mu}{\sigma}$$

$\mu$  et  $\sigma$  sont la moyenne et l'écart-type de la colonne, **appris sur le train**. Lecture :  $z = 0$ , valeur parfaitement moyenne ;  $z = +2$ , deux écarts-types au-dessus — grand, quelle que soit l'unité d'origine. Toutes les colonnes parlent désormais la même langue.

# Exemple — un z-score en chiffres

## La glycémie sur le train de Pima

Sur les 614 patientes d'entraînement :  $\mu_{\text{glycémie}} = 121,6$  et  $\sigma_{\text{glycémie}} = 30,0$ .

Une patiente à glycémie 180 :  $z = \frac{180 - 121,6}{30,0} = \frac{58,4}{30,0} = 1,95$  — presque deux écarts-types au-dessus de la moyenne : nettement élevée.

Même opération pour chaque colonne avec ses  $\mu$  et  $\sigma$  : l'insuline ( $\mu = 139,4$ ,  $\sigma = 84,4$ ) et l'âge ( $\mu = 33,6$ ,  $\sigma = 11,9$ ) deviennent comparables terme à terme.

# Exercice — standardiser à la main

## Énoncé

Sur le train, l'âge a pour moyenne  $\mu = 33,6$  et pour écart-type  $\sigma = 11,9$ . Calculer le z-score d'une patiente de 57 ans, et interpréter.

## Correction

$$z = \frac{57 - 33,6}{11,9} = \frac{23,4}{11,9} = 1,97 \text{ — environ deux écarts-types au-dessus de la moyenne :}$$

cette patiente est nettement plus âgée que la population du registre, exactement comme la glycémie 180 l'était pour sa colonne. Les deux  $z$  se comparent directement : c'est tout l'intérêt.

# Avant / après, en image

À l'échelle réelle (mêmes unités sur les deux axes), avant / après

Échelles brutes : l'insuline écrase l'âge



Après standardisation : à armes égales



À gauche, âge et insuline tracés *dans les mêmes unités* : l'âge disparaît, toute distance entre patientes est dictée par l'insuline. À droite, après standardisation : les deux variables pèsent selon leurs écarts réels. L'arbre de la Séance 3, qui coupe colonne par colonne, n'y était pas sensible — le modèle qui arrive l'est *viscéralement*.


# Un second modèle : les $k$ plus proches voisins

# L'idée : on prédit comme ses semblables

## Analogie

Pour estimer un loyer, un courtier ne résout pas d'équation : il regarde les maisons *voisines et comparables*, et annonce un loyer semblable. Les  $k$  plus proches voisins automatisent ce réflexe : « les patientes au profil proche ont connu telle issue ».

$k = 5$  voisins : 4 de classe 1, 1 de classe 0 → prédiction 1



Classer la patiente  $\star$  : trouver ses  $k = 5$  voisines, prendre la classe **majoritaire** — ici 4 contre 1, prédiction 1.

# La distance euclidienne, formellement

## Mesurer la proximité

« Proche » exige une **distance**. La distance euclidienne entre deux patientes est la longueur du segment qui les relie dans l'espace des caractéristiques — le théorème de Pythagore, en dimension  $d$ .

$$d(x, x') = \sqrt{\sum_{j=1}^d (x_j - x'_j)^2}$$

## Exemple numérique

En dimension 2 :  $d((3, 4), (0, 0)) = \sqrt{3^2 + 4^2} = \sqrt{9 + 16} = \sqrt{25} = 5$ . Chaque caractéristique contribue par son écart *au carré* — un grand écart sur une seule colonne suffit à dominer toute la somme. Retenir ce détail : il explique tout ce qui suit.

# Le modèle kNN, formellement

## Définition

Le modèle des  $k$  **plus proches voisins** prédit, pour une entrée  $x$ , la classe **majoritaire** parmi les  $k$  exemples d'entraînement les plus proches de  $x$ .

$$f(x) = \text{majorité} \{ y_i : x_i \in V_k(x) \}$$

$V_k(x)$  est l'ensemble des  $k$  voisins les plus proches de  $x$  dans le jeu d'entraînement. Particularité frappante : il n'y a *rien à entraîner* — **fit** se contente de **mémoriser** les exemples ; tout le travail (calculer les distances, voter) a lieu au moment de **predict**. C'est l'exact opposé de l'arbre, qui travaille à l'entraînement et prédit en un éclair.

## Exemple — classer à la main avec $k = 3$

Cinq voisines connues, une patiente à classer en  $x$  égal (4 ; 4)

| voisine | coord. | classe | distance à (4, 4)   | rang            |
|---------|--------|--------|---------------------|-----------------|
| A       | (5, 5) | 1      | $\sqrt{1+1} = 1,41$ | 1 <sup>er</sup> |
| B       | (2, 4) | 0      | $\sqrt{4+0} = 2,00$ | 2 <sup>e</sup>  |
| C       | (6, 3) | 1      | $\sqrt{4+1} = 2,24$ | 3 <sup>e</sup>  |
| D       | (1, 1) | 0      | $\sqrt{9+9} = 4,24$ | —               |
| E       | (7, 7) | 1      | $\sqrt{9+9} = 4,24$ | —               |

$V_3 = \{A, B, C\}$ , classes  $\{1, 0, 1\}$  : majorité 1 —  $f((4, 4)) = 1$ .

# Exercice — refaire le vote avec $k = 5$

## Énoncé

Mêmes cinq voisines, même patiente (4, 4). Donner la prédiction pour  $k = 5$ , puis expliquer pourquoi on choisit presque toujours  $k$  impair en classification binaire.

## Correction

$V_5$  = toutes les voisines, classes  $\{1, 0, 1, 0, 1\}$  : trois voix contre deux, prédiction 1. Un  $k$  pair autoriserait des votes à égalité (2-2), qu'il faudrait trancher arbitrairement ; un  $k$  impair garantit toujours une majorité nette.

# Pourquoi l'échelle est une condition de validité

## Trois patientes en deux mesures — âge et insuline

$A = (25, 100)$ ,  $B = (26, 400)$ ,  $C = (60, 105)$ . Qui est la plus proche de  $A$  ?

**En brut** :  $d(A, B) = \sqrt{1^2 + 300^2} = 300,0$  ; ;  $d(A, C) = \sqrt{35^2 + 5^2} = 35,4$  — la sexagénaire  $C$  paraît 8 fois plus proche de la jeune  $A$  que  $B$ , son quasi-jumeau d'âge : **l'insuline a tout écrasé.**

**Standardisé** (avec les  $\mu, \sigma$  du train, après imputation) :  $d(A, B) = 3,55$  ; ;  $d(A, C) = 2,95$  — l'ordre s'inverse,  $B$  redevient la plus proche, chaque variable pesant selon ses écarts réels.

Sur Pima en entier, le verdict chiffré : kNN ( $k = 5$ ) **sans** standardisation = 0,714 ; **avec** = 0,727. Pour un modèle à distances, la mise à l'échelle n'est pas un raffinement — c'est une **condition de validité** du calcul lui-même.

# Le réglage $k$ : la complexité, encore elle



Attention au sens de lecture : **petit  $k$  = modèle complexe**. À  $k = 1$ , chaque patiente du train est sa propre voisine — train 100 %, test 0,688 : pure mémorisation, le tailleur qui recoud à chaque essayage (**variance**). À  $k$  très grand, le vote noie tout détail local — le patron unique (**biais**). Le meilleur test :  $k = 22$ , accuracy 0,786.

# Exercice — diagnostiquer par la paire de scores

## Énoncé

Trois réglages du kNN sur Pima : **A**  $k = 1 : (1,000; 0,688)$  ; **B**  $k = 22 : (0,79; 0,786)$  ; **C**  $k = 300$  : scores faibles et proches tous les deux. Diagnostiquer chacun avec le vocabulaire de la Séance 3.

## Correction

**A** : écart majeur train/test — **sur-apprentissage** (variance) ; mémoriser ses voisines n'est pas généraliser. **B** : scores corrects et proches — le bon compromis. **C** : avec 300 voisines sur 614, le vote tend vers la classe majoritaire globale — **sous-apprentissage** (biais), le modèle redevient presque la baseline. La grille de lecture de la Séance 3 s'applique mot pour mot : seul le bouton de complexité a changé de nom.

# La fuite de données

# L'idée : un examen dont les questions ont fuité

## Analogie

Un étudiant obtient 20/20 — puis on découvre que le sujet de l'examen avait circulé la veille. Sa note ne mesure plus sa compréhension : elle mesure la fuite. En ML, le « sujet » est le jeu de test : toute information qui s'en échappe vers l'apprentissage fabrique un score menteur.

## Définition


Il y a **fuite de données** (*data leakage*) lorsque l'apprentissage utilise une information qui ne sera **pas disponible au moment de la prédiction** — ou qui provient du jeu de test. Le score mesuré est alors trop beau, et le modèle déployé déçoit.

Deux familles : la **variable fuyarde** (une colonne qui contient la réponse) et le **prétraitement fuyard** (des paramètres appris sur le test). Démonstration de chacune.

# Fuite n°1 — la variable fuyarde

## La démonstration sur Pima

Ajoutons une colonne « **traitement** » (1 si un traitement antidiabétique a été prescrit).  
L'arbre, réentraîné : accuracy = 1,000. Parfait ? Non — le traitement vient *après* le diagnostic : la colonne **contient la réponse**, et à l'admission, au moment de prédire, elle n'existera pas.



Le test à appliquer à *chaque* colonne : « cette information existera-t-elle **au moment de prédire** ? » Si non, elle sort — quel que soit le score qu'elle promet.

# Fuite n°2 — le prétraitement fuyard

## Le mécanisme

Médianes,  $\mu$ ,  $\sigma$  : tous les paramètres de préparation sont *appris*. Les apprendre sur le jeu **complet** — test inclus — c'est laisser le test influencer l'apprentissage : le modèle a « vu » la moyenne de l'examen avant de le passer.

## Sur Pima — un poison discret

Protocole fuyard (standardisation apprise sur les 768 patientes, split ensuite) : 0,727.  
Protocole honnête : 0,727 aussi — ici, l'écart est *invisible*. C'est précisément ce qui rend cette fuite dangereuse : elle ne se voit pas au score, le protocole ment *par construction*, et sur d'autres jeux (séries temporelles, petits échantillons) l'écart devient majeur. La règle ne se négocie pas au cas par cas : **tout fit se fait sur le train**.

# Exercice — repérer la fuite

## Énoncé

Pour chaque protocole, dire s'il y a fuite et laquelle : **(a)** prédire une réadmission avec la colonne « durée totale du séjour » ; **(b)** standardiser tout le jeu, puis faire le split train/test ; **(c)** imputer le train avec les médianes du train, puis le test avec *ces mêmes* médianes.


## Correction

**(a)** Variable fuyarde : la durée n'est connue qu'à *la sortie* — au moment de prédire la réadmission, elle n'existe pas encore sous sa forme finale. **(b)** Prétraitement fuyard :  $\mu$  et  $\sigma$  ont vu le test. **(c) Aucune fuite** — c'est exactement le bon protocole : paramètres appris sur le train, appliqués tels quels au test. Appliquer n'est pas apprendre.

# Le Pipeline : souder la chaîne

# L'idée : une seule chaîne, soudée

Pipeline scikit-learn : une seule chaîne soudée,  $f = m \circ \varphi$



Imputer, standardiser, prédire : trois maillons, chacun avec ses paramètres appris. Les enchaîner à la main multiplie les occasions de fuite (un `fit` de trop, un ordre inversé). Le **Pipeline** soude la chaîne : un seul `fit` (sur le train), un seul `predict` — la fuite de prétraitement devient *impossible par construction*.

# Le Pipeline, formellement

## Définition

Le modèle complet est la **composée** d'un prétraitement  $\varphi$  et d'un prédicteur  $m$  : d'abord transformer, ensuite prédire. Le prétraitement porte ses propres paramètres appris  $\theta_\varphi$  — les médianes, les  $\mu$  et les  $\sigma$ .

$$f(x) = m(\varphi(x)) \quad \text{avec } \theta_\varphi \text{ appris sur le train uniquement}$$

Lire de droite à gauche, comme toute composée :  $x$  entre,  $\varphi$  le répare et le met à l'échelle,  $m$  prédit. Le **fit** du Pipeline apprend *tout* d'un coup —  $\theta_\varphi$  puis les paramètres de  $m$  — sur les mêmes données d'entraînement ; le test ne traverse la chaîne qu'en **transform** et **predict**.

# Exemple — $\varphi(x)$ pas à pas sur une patiente

La patiente n°525 du test traverse la chaîne

| étape            | glycémie                          | insuline                             | âge                              |
|------------------|-----------------------------------|--------------------------------------|----------------------------------|
| brut             | 87                                | NaN                                  | 21                               |
| après imputation | 87                                | 125,5                                | 21                               |
| après z-score    | $\frac{87 - 121,6}{30,0} = -1,16$ | $\frac{125,5 - 139,4}{84,4} = -0,16$ | $\frac{21 - 33,6}{11,9} = -1,06$ |

Chaque nombre utilisé (125,5 ; 121,6 ; 30,0 ; ...) vient du **train** : la patiente, elle, est du test — elle subit la chaîne, elle ne l'a jamais nourrie. Puis  $m$  (le kNN) vote sur ce vecteur réparé :  $f(x) = m(\varphi(x))$ .

# En pratique : Pipeline scikit-learn

```
from sklearn.pipeline import Pipeline
from sklearn.impute import SimpleImputer
from sklearn.preprocessing import StandardScaler
from sklearn.neighbors import KNeighborsClassifier

modele = Pipeline([
    ("imputation", SimpleImputer(strategy="median")),
    ("echelle", StandardScaler()),
    ("knn", KNeighborsClassifier(n_neighbors=22)),
])
modele.fit(X_train, y_train)      # UN fit : medianes, mu/sigma, voisins
modele.score(X_test, y_test)     # 0.786
```

Le triptyque `fit` / `predict` / `score` de la Séance 3, inchangé — le Pipeline est un modèle comme les autres. Toute la discipline anti-fuite tient dans ces deux lignes finales.

# Le bilan chiffré de la séance

## Tous les scores sur le même test — 154 patientes

| modèle                                   | accuracy (test)           |
|------------------------------------------|---------------------------|
| baseline (classe majoritaire)            | 0,649                     |
| arbre profondeur 4 + imputation          | 0,662                     |
| kNN $k = 5$ sans standardisation         | 0,714                     |
| kNN $k = 5$ , Pipeline complet           | 0,727                     |
| kNN $k = 22$ , Pipeline complet          | <b>0,786</b>              |
| <i>n'importe quoi + variable fuyarde</i> | <i>1{,}000 — mensonge</i> |

**Deux leçons.** Le kNN bien préparé bat nettement l'arbre — **aucun modèle n'est roi partout**. Et le saut de 0,662 à 0,786 ne tient pas à un coup de génie : la standardisation rend la distance du kNN *valide* (0,714  $\rightarrow$  0,727), le choix de modèle et le réglage de  $k$  font le reste — la **méthodologie**, pas la chance.

# Exercice — remettre la chaîne dans l'ordre

## Énoncé

Remettre dans l'ordre les cinq étapes d'une étude propre : **(1)** `score` sur le test ; **(2)** `train_test_split` ; **(3)** remplacer les zéros impossibles par `NaN` ; **(4)** `fit` du Pipeline sur le train ; **(5)** construire le Pipeline (imputation → échelle → modèle). Où une inversion 2 ↔ 4 créerait-elle une fuite ?

## Correction

Ordre : **3** → **2** → **5** → **4** → **1**. (Le remplacement 0 → `NaN` n'apprend rien — il peut précéder le split.) Inverser 2 et 4, c'est `fit` avant le découpage : médianes,  $\mu$  et  $\sigma$  appris sur les 768 patientes, test compris — la fuite n°2 exactement. Le split vient toujours *avant* tout `fit`.

# Synthèse

# Le protocole complet, version 2

## De bout en bout — mis à jour

**1.** Formuler :  $(X, y)$ . ; **2. Auditer** : zéros impossibles → NaN, taux de manquants, échelles, colonnes fuyardes. ; **3.** Découper : `train_test_split`. ; **4.** Construire le **Pipeline** : imputation → encodage → standardisation → modèle. ; **5.** `fit` sur le train — un seul, celui du Pipeline. ; **6.** `score` sur le test, contre la baseline. ; **7.** Diagnostiquer : paire (train, test), réglage de la complexité ( $k$ , profondeur).

L'étape 2 est la nouveauté profonde de la séance : avant cette séance, on modélisait ; désormais, on **audite avant de modéliser**.

# À retenir — Séance 4

## L'essentiel

- Les données réelles cachent leurs trous (zéros impossibles) ; on les expose (**NaN**, taux  $m_j$ ) puis on les répare par la **médiane** — robuste aux valeurs extrêmes — apprise sur le train.
- Les catégories s'encodent en **one-hot** ; les échelles s'alignent par le **z-score**  $z = (x - \mu)/\sigma$ .
- Le **kNN** prédit par vote des  $k$  voisins : sans mise à l'échelle, sa distance est dominée par les grandes colonnes — l'échelle est une *condition de validité*. Petit  $k$  = variance, grand  $k$  = biais.
- La **fuite de données** fabrique des scores menteurs : variable fuyarde (la réponse déguisée) ou prétraitement fuyard (**fit** hors du train).
- Le **Pipeline** soude  $f = m \circ \varphi$  : un seul **fit**, sur le train — la fuite de prétraitement devient impossible par construction.

# Pièges fréquents

- Prendre les zéros impossibles pour des mesures — ou jeter la moitié du jeu pour s'en débarrasser.
- Imputer par la moyenne sur des colonnes à valeurs extrêmes (179,4 contre 105 : la moyenne ne ressemble à personne).
- Encoder des catégories par des entiers ordonnés : une géométrie inventée que les distances prennent au sérieux.
- Nourrir un kNN de colonnes non standardisées : la distance n'écoute plus que les grands nombres.
- Croire un score parfait : 1,000 n'est pas une victoire, c'est une **alarme** — chercher la colonne fuyarde.
- Faire un `fit` (imputeur, scaler) avant le split, ou un `fit_transform` sur le test : tout `fit` vit sur le train.

# Prochaine séance

## Séance 5 — Prédire un nombre : la régression

Jusqu'ici, la cible était une classe. La Séance 5 prédit une **quantité** — une durée de séjour en jours — avec la régression linéaire : ses coefficients lisibles, ses métriques propres (MAE, RMSE,  $R^2$ ), et le même Pipeline, devenu indispensable : la régression linéaire *refuse* les **NaN**.

# Références

- A. Géron, *Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow*, 3<sup>e</sup> éd., O'Reilly, 2022.
- A. C. Müller, S. Guido, *Introduction to Machine Learning with Python*, O'Reilly, 2016.
- G. James, D. Witten, T. Hastie, R. Tibshirani, *An Introduction to Statistical Learning*, 2<sup>e</sup> éd., Springer, 2021.
- J. W. Smith *et al.*, « Using the ADAP learning algorithm to forecast the onset of diabetes mellitus », 1988 — le jeu Pima.
- Cours : Stanford CS229 ; Cornell CS4780.

# Ressources de la séance

- **Notebook** · [TP 4 — Des données propres](#) (32 Ko)
- **TD** · [Fiche d'exercices 4](#) (205 Ko)