

Fiche d'exercices — Séance 3 : l'apprentissage supervisé et l'arbre de décision

Introduction au ML – Dr. El Hadji Bassirou TOURÉ – DMI · FST · UCAD • Travail à la main, sans machine

Cette fiche reprend, exercice par exercice, les calculs de la Séance 3 : accuracy et baseline, dimensions et découpage, le modèle d'arbre en formule, entropie et Gini, la construction d'un arbre à la main, puis le diagnostic par la profondeur. Répondre directement sur la fiche.

Aides numériques (valables pour toute la fiche). $\log_2 3 = 1,585$. Entropie d'un nœud binaire dont une classe occupe la proportion p :

p	1/2	1/4 ou 3/4	1/3 ou 2/3	2/5 ou 3/5	1/5 ou 4/5
H	1,000	0,811	0,918	0,971	0,722

Un nœud *pur* (une seule classe) a $H = 0$.

Exercice 1 – Accuracy et baseline

Au dispensaire de Tivaouane, un modèle de dépistage a été testé sur 10 patients (P = paludisme, N = sain) :

patient	1	2	3	4	5	6	7	8	9	10
réalité y_i	N	N	P	N	N	N	P	N	N	N
prédiction $\hat{y}_i$	N	P	P	N	N	N	N	N	P	N
verdict ($\checkmark$ ou $\times$)										

(a) Remplir la ligne « verdict » en comparant y et $\hat{y}$ composante par composante.

Nombre de prédictions correctes :

(b) En déduire l'accuracy du modèle.

Espace de calcul :

accuracy =

(c) Calculer l'accuracy de la *baseline majoritaire* (le modèle qui prédit toujours la classe la plus fréquente du tableau).

Espace de calcul :

Classe majoritaire : accuracy de la baseline =

(d) Comparer les deux accuracies et conclure : ce modèle apporte-t-il quelque chose ?

.....
.....
.....

Exercice 2 – Dimensions et découpage

Une cohorte de Kaolack compte 1 200 patients, chacun décrit par 5 caractéristiques (âge, glycémie, hémoglobine, fièvre, saison) ; la cible est le paludisme, présent chez 12 % des patients.

(a) Dimensions de la matrice de design X : du vecteur cible y :

(b) Découpage train/test à 75/25.

Espace de calcul :

Train : patients Test : patients

(c) Le découpage est *stratifié*.

Espace de calcul :

Positifs dans le train : positifs dans le test :

(d) Sans stratification, qu'est-ce qui pourrait mal se passer ?

.....

Exercice 3 – Le modèle en formule : la somme d'indicateurs

La Séance 3 définit l'arbre formellement : il partitionne l'espace des entrées en M régions disjointes $R_1, \dots, R_M$ (les feuilles) et prédit

$$f(x) = \sum_{m=1}^M \hat{c}_m \mathbf{1}[x \in R_m],$$

où $\mathbf{1}[\cdot]$ vaut 1 si la condition est vraie et 0 sinon, et où $\hat{c}_m$ est la *classe majoritaire* des exemples d'entraînement tombés dans R_m .

Au poste de santé de Ziguinchor, l'arbre suivant a été construit (cible codée P = 1, N = 0) : la racine applique la coupure (fièvre, 38,5) ; le nœud droit (fièvre $\geq$ 38,5) applique ensuite la coupure (âge, 30) ; le nœud gauche est une feuille. Répartition des exemples d'entraînement :		
feuille	condition	exemples d'entraînement
R_1	fièvre < 38,5	1 P et 3 N
R_2	fièvre $\geq$ 38,5 et âge < 30	3 P et 0 N
R_3	fièvre $\geq$ 38,5 et âge $\geq$ 30	0 P et 1 N

(a) Déterminer les classes majoritaires (en code 0/1) : $\hat{c}_1 = \dots$ $\hat{c}_2 = \dots$ $\hat{c}_3 = \dots$

Écrire la formule complète de $f(x)$ pour cet arbre :

$f(x) = \dots$

(b) Pour chacun des trois patients, calculer les indicateurs *une à une*, puis $f(x)$:

patient x	$\mathbf{1}[x \in R_1]$	$\mathbf{1}[x \in R_2]$	$\mathbf{1}[x \in R_3]$	$f(x)$	prédiction (P/N)
(fièvre 39,0, âge 24)					
(fièvre 38,0, âge 70)					
(fièvre 40,2, âge 55)					

(c) Combien d'indicateurs valent 1 simultanément dans chaque cas ?

Expliquer pourquoi il ne peut pas en être autrement, et ce que cela implique pour la somme $\sum_m \hat{c}_m \mathbf{1}[x \in R_m]$.

.....

(d) Écrire les deux coupures de l'arbre sous la forme (j, s) de la séance :

nœud racine : $(j, s) = \dots$ nœud droit : $(j, s) = \dots$

(e) Les régions R_1, R_2, R_3 recouvrent-elles *tout* l'espace des entrées ? Justifier, puis dire ce qui se passerait pour f si une zone n'était couverte par aucune région.

.....

Exercice 4 – Entropie et indice de Gini

Trois nœuds d'un arbre contiennent : nœud A : 8 P / 0 N nœud B : 4 P / 4 N nœud C : 6 P / 2 N

(a) Sans aucun calcul, classer les trois nœuds du plus pur au moins pur :

(b) Calculer l'entropie $H = -\sum_k p_k \log_2 p_k$ de chaque nœud. Pour le nœud C , détailler le calcul à partir de $\log_2 3 = 1,585$.

$H_A = \dots\dots\dots$ $H_B = \dots\dots\dots$

H_C , calcul détaillé :

.....

.....

.....

.....

(c) Calculer l'indice de Gini $G = 1 - \sum_k p_k^2$ des trois nœuds.

Espace de calcul :

$G_A = \dots\dots\dots$ $G_B = \dots\dots\dots$ $G_C = \dots\dots\dots$

(d) Les deux mesures donnent-elles le même classement qu'en (a) ?

Valeurs extrêmes possibles pour un nœud à deux classes : $H \in \dots\dots\dots$ $G \in \dots\dots\dots$

Exercice 5 – Construire l'arbre à la main

Huit patients du district de Thiès (cible : paludisme, P/N) :

patient	fièvre (°C)	âge (ans)	cible
1	37,2	25	N
2	37,8	45	N
3	38,0	19	N
4	38,2	33	P
5	38,9	7	P
6	39,4	15	P
7	39,8	22	P
8	40,1	61	N

Gain d'une coupure : $\text{gain} = H(\text{parent}) - \left(\frac{n_g}{n} H(\text{gauche}) + \frac{n_d}{n} H(\text{droite}) \right)$.

(a) Entropie de la racine : composition (P/N) : $\Rightarrow H(\text{racine}) = \dots\dots\dots$

(b) **Le duel.** Deux coupures candidates pour la racine : A = (fièvre, 38,5) et B = (âge, 30). Compléter :

coupure	gauche (P/N)	$H(\text{gauche})$	droite (P/N)	$H(\text{droite})$	gain
A : (fièvre, 38,5)					
B : (âge, 30)					

Espace de calcul :

Coupure retenue : Justification :

(c) **Purifier le nœud gauche** (fièvre $< 38,5$, patients 1 à 4). Deux candidates : (fièvre, 38,1) et (âge, 30).

Espace de calcul :

gain de (fièvre, 38,1) = gain de (âge, 30) = retenue :

(d) **Purifier le nœud droit** (fièvre $\geq 38,5$, patients 5 à 8) avec la candidate (âge, 30).

Espace de calcul :

gain = Pourquoi la construction s'arrête-t-elle ici ?

(e) Dessiner l'arbre final (nœuds avec leurs coupures, feuilles avec leur classe), puis vérifier qu'il classe correctement les 8 patients d'entraînement.

(f) Nouveau patient : fièvre 38,3, âge 28. Suivre son chemin nœud par nœud et donner la prédiction.

.....

.....

Prédiction :

(g) **Retour à la formule.** Écrire les régions $R_1, \dots, R_4$ de l'arbre final et la valeur $\hat{c}_m$ de chacune — autrement dit, le $f(x)$ de l'exercice 3 pour *cet* arbre.

région	condition	$\hat{c}_m$
R_1		
R_2		
R_3		
R_4		

$f(x) =$

Exercice 6 – Profondeur et diagnostic

Sur un jeu de dépistage, trois arbres ont été entraînés puis évalués. Baseline majoritaire : 0,61.

profondeur	accuracy train	accuracy test	écart train – test	diagnostic
2	0,74	0,73		
5	0,85	0,83		
14	0,99	0,76		

(a) Remplir la colonne des écarts.

(b) Remplir la colonne diagnostic (sous-ajusté / bien ajusté / sur-ajusté), puis justifier chaque diagnostic en une phrase, en s'appuyant sur les écarts *et* sur la baseline.

profondeur 2 :

.....

profondeur 5 :

.....

profondeur 14 :

.....

(c) Profondeur à retenir : sur la foi de quel chiffre ?

(d) L'arbre de profondeur 14 a la meilleure accuracy d'entraînement. Expliquer pourquoi ce chiffre ne doit jamais servir à choisir un modèle.

.....

.....

.....

.....