

Fiche d'exercices — Séance 4 : des données propres, préparer avant d'apprendre

Introduction au ML – Dr. El Hadji Bassirou TOURÉ – DMI · FST · UCAD • Travail à la main, sans machine

Cette fiche reprend, exercice par exercice, les calculs de la Séance 4 : taux de manquants, imputation par la médiane, encodage one-hot, standardisation (z-score), le modèle des k plus proches voisins à la main, le réglage de k par la paire de scores, puis la fuite de données et le Pipeline $f = m \circ \varphi$. Répondre directement sur la fiche.

Aides numériques (valables pour toute la fiche). Quelques racines carrées utiles :

u	1	2	2,5	4,09	8	10	13,70	1,049
$\sqrt{u}$	1,00	1,41	1,58	2,02	2,83	3,16	3,70	32,4

Médiane d'un nombre *pair* de valeurs = moyenne des deux valeurs centrales (valeurs triées). Distance euclidienne en dimension d : $d(x, x') = \sqrt{\sum_{j=1}^d (x_j - x'_j)^2}$.

Exercice 1 – Taux de manquants

Au poste de santé de Tivaouane, un registre de 400 patients a été audité. Après remplacement des zéros *impossibles* par NaN, on compte les valeurs manquantes par colonne :

colonne	glycémie	tension	insuline	IMC	fièvre
nombre de NaN	8	28	180	12	0
m_j					

(a) Rappeler la formule du taux de manquants m_j , puis remplir la dernière ligne du tableau.

Espace de calcul :

(b) On envisage de *jeter* toute ligne contenant au moins un trou. En supposant que les colonnes à trous ne se chevauchent pas, combien de patients perdrait-on au plus ? Combien en resterait-il ? Quelle proportion du jeu cela représente-t-il ?

Espace de calcul :

Patients perdus (au plus) : restants : proportion perdue :

(c) Pour chacune des cinq colonnes, proposer le traitement le plus raisonnable (imputation par la médiane / aucune action), et justifier en une ligne.

.....
.....
.....

Exercice 2 – Médiane et imputation

Une mini-colonne d'insuline ($\mu\text{U/mL}$) de huit patients, après remplacement des zéros impossibles, contient :

92 NaN 145 110 NaN 130 88 410

(a) Trier les valeurs observées (sans les NaN), puis calculer la médiane.

Espace de calcul :

Valeurs triées :

médiane =

(b) Donner la colonne après imputation par la médiane (les valeurs observées ne bougent pas).

position	1	2	3	4	5	6	7	8
valeur imputée								

(c) Calculer la moyenne des valeurs observées. Combien de valeurs observées la moyenne dépasse-t-elle ? Conclure : pourquoi la médiane est-elle préférable ici ?

Espace de calcul :

moyenne = la moyenne dépasse valeurs sur 6.

.....

Exercice 3 – Encodage one-hot

Une colonne « groupe sanguin » prend quatre modalités : **A**, **AB**, **B**, **O** (rangées dans cet ordre alphabétique).

(a) Combien de colonnes binaires le one-hot produit-il ?

(b) Encoder les trois patients suivants (une case « chaude » par ligne) :

groupe	A	AB	B	O
« B »				
« O »				
« AB »				

(c) Pourquoi ne pas coder simplement $A = 1$, $AB = 2$, $B = 3$, $O = 4$? Expliquer en termes d'*ordre* et de *distance*.

.....

(d) Calculer la distance euclidienne entre les vecteurs one-hot de « A » et de « B ». Que vaudrait-elle pour deux modalités *quelconques* distinctes ? Qu'en conclure sur la géométrie produite par le one-hot ?

Espace de calcul :

$d(\text{one-hot A, one-hot B}) = \dots\dots\dots$

.....

Exercice 4 – Standardisation (z-score)

Sur le jeu d'*entraînement*, deux colonnes ont les statistiques suivantes : hémoglobine $\mu = 12,5$, $\sigma = 1,8$ (g/dL) glycémie $\mu = 120$, $\sigma = 28$ (mg/dL).

(a) Rappeler la formule du z-score, puis calculer celui d'un patient à hémoglobine 15,2 g/dL. Interpréter en une phrase.

Espace de calcul :

$z = \dots\dots\dots$

.....

(b) Un patient du jeu de *test* a une hémoglobine de 9,8 g/dL. Calculer son z-score. **Question clé :** faut-il recalculer μ et σ en incluant ce patient ? Justifier.

Espace de calcul :

$z = \dots\dots\dots$

$\dots\dots\dots$
 $\dots\dots\dots$

(c) Un troisième patient a une glycémie de 162 mg/dL. Calculer son z-score, et le comparer à celui de la question (a). Que permet cette comparaison, alors que les deux colonnes ont des unités différentes ?

Espace de calcul :

$z = \dots\dots\dots$

$\dots\dots\dots$

Exercice 5 – Les k plus proches voisins, à la main

Cinq patients d'entraînement sont décrits par deux caractéristiques **déjà standardisées** (z_1, z_2) et une classe ($P = 1$, $N = 0$). On veut classer un nouveau patient $\star = (0,0, 1,0)$.

voisin	z_1	z_2	classe
A	1,0	2,0	1
B	−1,0	1,0	0
C	0,5	−0,5	1
D	3,0	0,0	1
E	−2,0	−1,0	0

(a) Calculer la distance euclidienne de chaque voisin à $\star$, puis donner le rang (du plus proche au plus lointain).

voisin	calcul de la distance	distance	rang
A			
B			
C			
D			
E			

(b) Donner la prédiction pour $k = 3$: voisins retenus $\dots\dots\dots$ classes $\dots\dots\dots$ $f(\star) = \dots\dots$

(c) Donner la prédiction pour $k = 5$: classes $\dots\dots\dots$ $f(\star) = \dots\dots$

(d) Pourquoi choisit-on presque toujours k *impair* en classification binaire ?

$\dots\dots\dots$
 $\dots\dots\dots$

(e) **L'échelle est une condition de validité.** Trois patients sont décrits par (âge, insuline) en unités *brutes* : Awa = (28, 100), Cheikh = (31, 300), Fatou = (65, 108). Sur le train, âge : $\mu = 35$, $\sigma = 10$; insuline : $\mu = 150$, $\sigma = 100$.

(e.1) En unités brutes, calculer $d(\text{Awa}, \text{Cheikh})$ et $d(\text{Awa}, \text{Fatou})$. Qui paraît la plus proche d'Awa ?

Espace de calcul :

$d_{\text{brut}}(\text{Awa}, \text{Cheikh}) = \dots\dots\dots$ $d_{\text{brut}}(\text{Awa}, \text{Fatou}) = \dots\dots\dots$ plus proche : $\dots\dots\dots$

(e.2) Standardiser les trois patients (z-score de chaque coordonnée), puis recalculer les deux distances. Qui est maintenant la plus proche d'Awa ?

Espace de calcul :

$d_{\text{std}}(\text{Awa}, \text{Cheikh}) = \dots\dots\dots$ $d_{\text{std}}(\text{Awa}, \text{Fatou}) = \dots\dots\dots$ plus proche : $\dots\dots\dots$

(e.3) L'ordre des voisins s'est-il inversé ? Expliquer en une phrase ce que la standardisation a corrigé.

$\dots\dots\dots$
 $\dots\dots\dots$

Exercice 6 – Le réglage de k : diagnostic

Sur un jeu de dépistage, le kNN a été entraîné puis évalué pour trois valeurs de k . Baseline majoritaire : 0,66. **Attention au sens de lecture : un *petit* k donne un modèle *complexe*.**

k	accuracy train	accuracy test	écart train – test	diagnostic
1	1,00	0,71		
15	0,80	0,78		
300	0,67	0,66		

(a) Remplir la colonne des écarts.

(b) Remplir la colonne diagnostic (sous-ajusté / bien ajusté / sur-ajusté), puis justifier chaque cas en une phrase, en s'appuyant sur l'écart *et* sur la baseline.

$k = 1$: $\dots\dots\dots$
 $\dots\dots\dots$

$k = 15$: $\dots\dots\dots$
 $\dots\dots\dots$

$k = 300$: $\dots\dots\dots$
 $\dots\dots\dots$

(c) Valeur de k à retenir : $\dots\dots\dots$ sur la foi de quel chiffre ? $\dots\dots\dots$

(d) Le réglage $k = 1$ a la meilleure accuracy d'entraînement (1,00). Expliquer pourquoi ce chiffre ne doit jamais servir à choisir un modèle, et faire le lien avec la profondeur de l'arbre (Séance 3).

$\dots\dots\dots$
 $\dots\dots\dots$
 $\dots\dots\dots$

Exercice 7 – Fuite de données et Pipeline

(a) Pour chaque protocole, dire s'il y a *fuite* et, le cas échéant, laquelle : **variable fuyarde** (une colonne contient la réponse) ou **prétraitement fuyard** (μ , σ , médianes appris hors du train).

protocole	fuite ? laquelle ?
(1) Prédire une réadmission avec la colonne « durée du séjour courant ».	
(2) Standardiser tout le jeu, <i>puis</i> faire le split train/test.	
(3) Imputer le train avec les médianes du train, puis le test avec <i>ces mêmes</i> médianes.	
(4) Faire le split, puis appeler <code>fit_transform</code> du scaler sur le jeu de <i>test</i> .	

(b) **La chaîne φ à la main.** Un patient du *test* traverse le Pipeline $f = m \circ \varphi$. Les paramètres ont été appris sur le *train* : $\text{med}_{\text{insuline}} = 120$; glycémie $\mu = 120$, $\sigma = 28$; insuline $\mu = 150$, $\sigma = 100$; âge $\mu = 35$, $\sigma = 10$. Remplir le tableau étape par étape.

étape	glycémie	insuline	âge
brut	162	NaN	28
après imputation			
après z-score			

Chaque nombre injecté vient-il du train ou du test ? Pourquoi est-ce essentiel ?

.....

.....

(c) **Remettre la chaîne dans l'ordre.** Les cinq étapes d'une étude propre, en désordre : (1) score sur le test ; (2) `train_test_split` ; (3) remplacer les zéros impossibles par NaN ; (4) `fit` du Pipeline sur le train ; (5) construire le Pipeline (imputation → standardisation → modèle).

Ordre correct :

Où une inversion de 2 et 4 (`fit` avant le `split`) créerait-elle une fuite, et de quel type ?

.....

.....