

Fiche d'exercices — Séance 5 : la régression linéaire

Introduction au ML – Dr. El Hadji Bassirou TOURÉ – DMI · FST · UCAD • Travail à la main, sans machine

Cette fiche reprend, exercice par exercice, les calculs de la Séance 5 : lire un coefficient et prédire terme à terme, comparer deux droites par la MSE, la droite plate, l'équation normale à une variable, une itération de descente de gradient, les métriques MAE/RMSE/ R^2 , puis l'effet de la régularisation. Répondre directement sur la fiche.

Rappels utiles (valables pour toute la fiche).

- Modèle linéaire : $\hat{y} = b + w_1x_1 + \dots + w_dx_d$. Résidu d'un point : $y - \hat{y}$.
- Erreur quadratique moyenne : $MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$. $RMSE = \sqrt{MSE}$. $MAE = \frac{1}{n} \sum_i |y_i - \hat{y}_i|$.
- Équation normale à une variable : $a = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2}$, $b = \bar{y} - a\bar{x}$.
- Descente de gradient (modèle $\hat{y} = ax$, un paramètre) : gradient $g = -\frac{2}{n} \sum_i x_i (y_i - ax_i)$, mise à jour $a \leftarrow a - \eta g$.
- Coefficient de détermination : $R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$.

Exercice 1 – Lire un coefficient et prédire

Un modèle prédit la durée d'hospitalisation (en jours) à partir de l'âge et de la glycémie d'un patient :

$$\hat{y} = 1,2 + 0,05(\text{âge}) + 0,60(\text{glycémie}).$$

(a) Un patient de Ziguinchor a âge = 40 ans et glycémie = 9,0. Calculer sa durée prédite $\hat{y}$, terme par terme.

Espace de calcul :

(b) Sa durée réelle a été $y = 6,0$ jours. Calculer le résidu $y - \hat{y}$. Le modèle a-t-il surestimé ou sous-estimé ?

(c) Interpréter le coefficient 0,60 de la glycémie en une phrase : que se passe-t-il sur la prédiction si la glycémie augmente d'une unité (l'âge restant fixe) ?

Exercice 2 – Comparer deux droites par leur MSE

On dispose de quatre patients du dispensaire de Thiès, avec une caractéristique x (standardisée) et la durée y :

x_i	1	2	3	4
y_i	2,0	2,5	4,0	5,5

On hésite entre deux droites : droite A : $\hat{y} = 1 + x$ droite B : $\hat{y} = 0,5 + 1,2x$.

(a) Compléter le tableau des prédictions et des erreurs pour *chaque* droite, puis calculer la MSE de chacune.

	$x = 1$	$x = 2$	$x = 3$	$x = 4$	MSE
A : $\hat{y}_i$					
A : $y_i - \hat{y}_i$					
B : $\hat{y}_i$					
B : $y_i - \hat{y}_i$					

Espace de calcul :

(b) Laquelle des deux droites est la « meilleure » au sens de la MSE ? Justifier.

.....

.....

Exercice 3 – La droite plate (baseline)

La baseline d'une régression prédit, pour *tout* patient, la moyenne $\bar{y}$ des durées observées. Sur quatre patients de Kaolack : $y = (3,0, 5,0, 4,0, 8,0)$.

(a) Calculer la moyenne $\bar{y}$.

.....

(b) La droite plate prédit $\hat{y}_i = \bar{y}$ pour chaque patient. Calculer sa MSE. (On remarquera que cette MSE est exactement la *variance* des y_i .)

Espace de calcul :

(c) Quelle est la RMSE de cette baseline ? Dans quelle unité s'exprime-t-elle ?

.....

Exercice 4 – L'équation normale à une variable

On cherche la *meilleure* droite $\hat{y} = ax + b$ pour cinq patients de Saint-Louis :

x_i	1	2	3	4	5
y_i	2,0	4,0	5,0	4,0	6,0

(a) Calculer les moyennes $\bar{x}$ et $\bar{y}$.

.....

(b) Compléter le tableau, puis calculer la pente $a = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$.

	$i = 1$	$i = 2$	$i = 3$	$i = 4$	$i = 5$	somme
$x_i - \bar{x}$						
$y_i - \bar{y}$						
$(x_i - \bar{x})(y_i - \bar{y})$						
$(x_i - \bar{x})^2$						

Espace de calcul :

(c) En déduire l'ordonnée à l'origine $b = \bar{y} - a\bar{x}$, puis écrire l'équation de la droite.

.....

.....

Exercice 5 – Une itération de descente de gradient

On ajuste un modèle *sans biais* à un seul paramètre, $\hat{y} = ax$, sur trois points : $x = (1, 2, 3)$, $y = (2, 4, 6)$. Le critère est $J(a) = \frac{1}{n} \sum_i (y_i - ax_i)^2$, et son gradient $g = -\frac{2}{n} \sum_i x_i (y_i - ax_i)$.

(a) On part de $a_0 = 0$. Calculer les prédictions $\hat{y}_i = a_0 x_i$, puis le gradient g en ce point.

Espace de calcul :

(b) Avec un pas $\eta = 0,1$, calculer la nouvelle valeur $a_1 = a_0 - \eta g$.

(c) Vers quelle valeur de a cette descente va-t-elle converger ? (Indice : quelle pente passe exactement par les trois points ?)

Exercice 6 – MAE, RMSE et R^2

Un modèle de régression a produit, sur quatre patients de Tivaouane, les durées réelles y et prédites $\hat{y}$:

y_i	10	12	8	15
$\hat{y}_i$	11	11	9	13
$y_i - \hat{y}_i$				

(a) Compléter la ligne des erreurs, puis calculer la MAE et la RMSE.

Espace de calcul :

(b) La RMSE est-elle plus grande ou plus petite que la MAE ? Expliquer pourquoi en une phrase.

(c) Sachant que $\bar{y} = 11,25$ et que $\sum_i (y_i - \bar{y})^2 = 26,75$, calculer le R^2 du modèle. Le modèle fait-il mieux que la baseline-moyenne ?

Espace de calcul :

Exercice 7 – Ridge et Lasso

Sur un jeu de variables standardisées, on entraîne une régression Ridge avec différentes valeurs de α . On observe la pente associée à une variable :

α	0	1	10	100
pente obtenue	2,00	1,67	0,67	0,095

(a) Décrire en une phrase l'effet de α sur la pente, à la lecture du tableau.

(b) Vers quel modèle tend Ridge quand $\alpha \rightarrow \infty$? Que vaut alors la prédiction pour tout patient ?

(c) Ridge réduit les coefficients sans les annuler ; Lasso, lui, peut mettre certains coefficients *exactement* à zéro. En une phrase, dire lequel des deux fait de la **sélection de variables**, et pourquoi c'est utile quand beaucoup de variables sont inutiles.

(d) Pourquoi faut-il **standardiser** les variables avant d'appliquer Ridge ou Lasso ? (Indice : la pénalité compare les coefficients entre eux.)

