Fiche d'exercices — Séance 6 : la classification

Introduction au ML – Dr. El Hadji Bassirou TOURÉ – DMI · FST · UCAD • **Travail à la main, sans machine**

Cette fiche reprend, exercice par exercice, les calculs de la Séance 6 : le score logistique passé dans la sigmoïde, la log-loss, la matrice de confusion et ses métriques, le seuil comme curseur, la courbe ROC et l'AUC construites à la main, puis le déséquilibre de classes et le choix de la métrique. Répondre directement sur la fiche.

Aides numériques (valables pour toute la fiche). Table de la sigmoïde $\sigma(z) = 1/(1+e^{-z})$:

z	-3	-2	-1	0	1	2	3
$\sigma(z)$	0,047	0,119	0,269	0,500	0,731	0,881	0,953

Logarithmes : $\ln 0{,}9 = -0{,}105$; $\ln 0{,}8 = -0{,}223$; $\ln 0{,}7 = -0{,}357$; $\ln 0{,}6 = -0{,}511$; $\ln 0{,}4 = -0{,}916$; $\ln 0{,}3 = -1{,}204$; $\ln 0{,}2 = -1{,}609$; $\ln 0{,}1 = -2{,}303$.

Exercice 1 – Du score à la probabilité, puis à la décision

Un modèle logistique a appris, sur des variables standardisées (âge, glycémie, fièvre), l'intercept $b = -1{,}2$ et les poids $\mathbf{w} = (0{,}6;\ -0{,}4;\ 1{,}0)$. Une patiente a pour valeurs standardisées $\mathbf{x} = (1{,}0;\ 1{,}5;\ 0{,}2)$.

(a) Calculer le score $z = b + \mathbf{w}\cdot\mathbf{x}$ terme à terme, puis la probabilité $\hat{p} = \sigma(z)$ (table).

Espace de calcul :

$z =$ .... $\hat{p} =$ ....

(b) Donner la décision au seuil 0,5, puis au seuil 0,2. seuil 0,5 : $\hat{y} =$ .... seuil 0,2 : $\hat{y} =$ ....

(c) Le poids de la glycémie est négatif. Que signifie ce signe, « toutes choses égales par ailleurs » ?

....

....

(d) Trois autres patients ont les scores $z = +3$, $z = 0$, $z = -2$. Pour lequel le modèle est-il le plus incertain ? Pourquoi ?

....

Exercice 2 – La log-loss à la main

Quatre prédictions sont jugées par la log-loss $J = -\frac{1}{n}\sum_i \big[y_i \ln \hat{p}_i + (1-y_i)\ln(1-\hat{p}_i)\big]$.

patient	$\hat{p}_i$	y_i	terme qui survit	perte
A	0,7	1		
B	0,4	1		
C	0,2	0		
D	0,9	0		

(a) Remplir le tableau (quel terme survit, et la perte de chaque patient). (b) Calculer la log-loss moyenne.

Espace de calcul :

$J =$ ....

(c) Quel patient coûte le plus cher ? Qu'est-ce que la log-loss punit, que l'accuracy ne voit pas ?

....

....

Exercice 3 – La matrice de confusion

Huit patients de dépistage à Kolda, triés par probabilité prédite décroissante (P = paludisme, $y = 1$) :

patient	1	2	3	4	5	6	7	8
$\hat{p}_i$	0,95	0,85	0,70	0,55	0,45	0,35	0,20	0,10
réalité y_i	1	1	1	0	0	1	1	0

Ce jeu sert aux Exercices 3, 4 et 5.

(a) Au seuil 0,5, écrire la décision $\hat{y}_i$ et la case (TP, FP, FN, TN) de chaque patient.

patient	1	2	3	4	5	6	7	8
$\hat{y}_i$ (seuil 0,5)								
case								

(b) Compléter la matrice, puis calculer accuracy, precision, recall et F1.

	prédit 1	prédit 0
réel 1	TP =	FN =
réel 0	FP =	TN =

accuracy = ... precision = ...

recall = ... F1 = ...

Espace de calcul :

(c) Traduire la precision et le recall en une phrase chacun, dans la langue d'un agent de santé.

....

....

Exercice 4 – Le seuil, un curseur

Même jeu de huit patients (Exercice 3). Le modèle ne change pas ; seul le seuil passe de 0,5 à 0,3.

(a) Quels patients changent de décision ? ....

(b) Recalculer TP, FP, FN, TN, puis precision, recall et F1 au seuil 0,3.

Espace de calcul :

TP = ... FP = ... FN = ... TN = ... precision = ... recall = ... F1 = ...

(c) Pour une campagne dont la consigne est « ne manquer presque aucun cas », quel seuil préférer ? Quelle métrique accepte-t-on de sacrifier ?

....

....

Exercice 5 – Construire la ROC et calculer l'AUC à la main

Même jeu (Exercice 3) : 5 positifs, 3 négatifs. On abaisse le seuil juste sous chaque $\hat{p}_i$, dans l'ordre décroissant.

(a) Compléter le tableau : chaque positif fait *monter*, chaque négatif pousse *à droite*.

le seuil passe sous	départ	0,95	0,85	0,70	0,55	0,45	0,35	0,20	0,10
TPR (sur 5)	0								
FPR (sur 3)	0								

(b) Tracer la courbe (escalier) dans le repère ci-dessous.

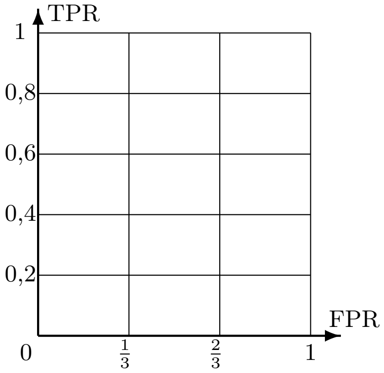

(c) Calculer l'AUC par les paires : nombre de paires (positif, négatif), nombre de paires mal ordonnées (négatif au-dessus d'un positif), puis AUC.

Espace de calcul :

paires = ... mal ordonnées = ... AUC = ...

(d) L'AUC dépend-elle du seuil ? Que juge-t-elle exactement ?

....

Exercice 6 – La classe rare et l'accuracy trompeuse

À Tambacounda, 1 000 patients sont dépistés ; 50 sont réellement malades.

(a) Un « modèle » répond toujours « sain ». Calculer son accuracy, son recall et sa precision.

Espace de calcul :

accuracy = ... recall = ... precision = ...

(b) Un vrai modèle affiche accuracy 0,93, recall 0,60. Est-il pire que le précédent ? Justifier.

....

....

(c) Trois modèles affichent AUC = 0,50, 0,88 et 0,25. Interpréter chacun.

....

....

(d) Que fait `class_weight="balanced"` à l'entraînement, et que ne change-t-il pas au jeu de test ?

....

Exercice 7 – Une métrique pour chaque mission

(a) Pour chaque situation, choisir la métrique à privilégier (precision, recall, F1 ou AUC) et justifier.

situation	métrique	raison
Dépistage du paludisme, test de confirmation bon marché.		
Envoi d'une équipe mobile coûteuse à chaque alerte.		
Comparer deux modèles avant d'avoir fixé le seuil.		

(b) Un collègue règle le seuil en choisissant celui qui maximise la F1 *sur le jeu de test*, puis annonce cette F1. Qu'est-ce qui ne va pas ? Comment faire proprement ?

....

....