

Fiche d'exercices — Séance 9 : apprendre sans étiquettes

Introduction au ML – Dr. El Hadji Bassirou TOURÉ – DMI · FST · UCAD • Travail à la main, sans machine

Cette fiche reprend, exercice par exercice, les calculs de la Séance 9 : k-means déroulé à la main (en une puis deux dimensions), l'inertie, le coude et la silhouette, l'effet de l'échelle, puis les fondations de l'ACP — variance, covariance, vecteurs propres — et la variance expliquée. Répondre directement sur la fiche.

Aides numériques (valables pour toute la fiche). Distance au carré : $\|\mathbf{x} - \mathbf{c}\|^2 = \sum_j (x_j - c_j)^2$. Inertie : $\mathcal{I} = \sum_k \sum_{i \in C_k} \|\mathbf{x}_i - \mathbf{c}_k\|^2$. Silhouette d'un point : $s = \frac{b-a}{\max(a,b)}$ (a : distance moyenne à son cluster, b : au cluster voisin). Variance $\text{Var}(x) = \frac{1}{n} \sum_i (x_i - \bar{x})^2$; covariance $\text{Cov}(x, y) = \frac{1}{n} \sum_i (x_i - \bar{x})(y_i - \bar{y})$; vecteur propre : $A\mathbf{v} = \lambda\mathbf{v}$; variance expliquée par la composante i : $\lambda_i / \sum_j \lambda_j$.

Exercice 1 – Une étape de k-means en une dimension

Cinq patients décrits par une seule variable : $x = 2, 3, 4, 10, 12$. On vise $k = 2$, avec les centres initiaux (mal choisis) $c_1 = 2$ et $c_2 = 3$.

(a) Affecter chaque point au centre le plus proche, puis recalculer les deux centres.

Espace de calcul :

clusters : $c_1 = \dots\dots\dots$ $c_2 = \dots\dots\dots$

(b) Réaffecter avec les nouveaux centres, puis recalculer. Continuer jusqu'à ce que plus rien ne change. Combien d'itérations ?

Espace de calcul :

clusters finaux : centres finaux :

(c) Calculer l'inertie avec les centres initiaux (2 et 3), puis l'inertie finale. Que constate-t-on ?

Espace de calcul :

inertie initiale = inertie finale =

Exercice 2 – k-means à la main, en deux dimensions

Six patients (deux mesures exprimées sur une même échelle) : $A(1,1)$, $B(3,1)$, $C(2,4)$, $D(7,7)$, $E(9,7)$, $F(8,10)$. On vise $k = 2$, avec des centres initiaux volontairement médiocres : $\mathbf{c}_1 = A = (1,1)$ et $\mathbf{c}_2 = C = (2,4)$.

(a) **Affectation 1.** Calculer la distance au carré de chaque point aux deux centres, puis affecter.

point	A	B	C	D	E	F
d^2 à $\mathbf{c}_1 = (1,1)$						
d^2 à $\mathbf{c}_2 = (2,4)$						
cluster						

Inertie après l'affectation 1 :

(b) **Mise à jour 1.** Recalculer les deux centres (moyennes des clusters).

Espace de calcul :

$\mathbf{c}_1 = \dots\dots\dots$ $\mathbf{c}_2 = \dots\dots\dots$

(c) **Affectation 2 et mise à jour 2.** Quel point change de cluster ? Donner les nouveaux centres et l'inertie.

Espace de calcul :

point qui change : $\mathbf{c}_1 =$ $\mathbf{c}_2 =$ inertie =

(d) Une troisième affectation change-t-elle quelque chose ? Donner l'inertie finale, et dire si k-means garantit toujours la meilleure solution.

Espace de calcul :

inertie finale =

.....

Exercice 3 – Combien de clusters ? Coude et silhouette

(a) Sur un jeu de patients, l'inertie vaut, selon k :

k	1	2	3	4	5	6
inertie	900	420	180	150	128	110

Calculer le gain d'inertie à chaque ajout de cluster, puis désigner le « coude ».

Espace de calcul :

gains : coude : $k =$

(b) Pourquoi ne choisit-on pas le k qui minimise l'inertie ?

.....

(c) Calculer la silhouette de trois points et interpréter chacune.

point	a	b	s	interprétation
P	1,2	4,0		
Q	3,0	2,5		
R	2,0	2,2		

Exercice 4 – k-means et l'échelle des variables

Trois patients sont décrits par (âge en années, glycémie en g/L) : Awa (30; 1,0), Binta (34; 2,2), Coumba (50; 1,0). Sur le jeu, âge : $\sigma = 10$; glycémie : $\sigma = 0,5$.

(a) En unités brutes, calculer $d^2(\text{Awa}, \text{Binta})$ et $d^2(\text{Awa}, \text{Coumba})$. Qui est la plus proche d'Awa ?

Espace de calcul :

(b) Diviser chaque variable par son écart-type (le centrage ne change pas les distances), puis recalculer les deux distances au carré. Qui est maintenant la plus proche ?

Espace de calcul :

(c) Qu'aurait fait k-means sans standardisation sur ce jeu ?

.....

.....

Exercice 5 – Variance et covariance

Deux variables mesurées sur quatre patients : $x = (1, 3, 5, 7)$ et $y = (2, 3, 7, 8)$.

(a) Calculer les moyennes, puis $\text{Var}(x)$, $\text{Var}(y)$ et $\text{Cov}(x, y)$.

patient	$x_i - \bar{x}$	$y_i - \bar{y}$	$(x_i - \bar{x})^2$	$(y_i - \bar{y})^2$	$(x_i - \bar{x})(y_i - \bar{y})$
1					
2					
3					
4					
moyenne	—	—			

(b) Écrire la matrice de covariance. Le signe de la covariance était-il prévisible ?

Espace de calcul :

.....

Exercice 6 – Vecteurs propres d’une matrice de covariance

Soit la matrice de covariance $C = \begin{pmatrix} 5 & 3 \\ 3 & 5 \end{pmatrix}$.

(a) Calculer $C(1; 1)^\top$ et $C(1; -1)^\top$. En déduire que ce sont des vecteurs propres, et leurs valeurs propres.

Espace de calcul :

$\lambda_1 = \dots\dots\dots$ (vecteur $\dots\dots\dots$) $\lambda_2 = \dots\dots\dots$ (vecteur $\dots\dots\dots$)

(b) Quelle est la direction de plus grande variance ? Quelle part de la variance totale porte-t-elle ?

Espace de calcul :

.....

(c) Normaliser le premier vecteur propre (longueur 1). C’est la première composante principale.

.....

Exercice 7 – La variance expliquée : combien de composantes garder ?

Une ACP sur six variables standardisées d’un registre de santé donne les valeurs propres :

$$\lambda = (2,4; 1,2; 0,9; 0,7; 0,5; 0,3) \quad (\text{somme} = 6).$$

(a) Compléter la variance expliquée et la variance cumulée.

composante	PC1	PC2	PC3	PC4	PC5	PC6
part expliquée						
cumul						

(b) Combien de composantes garder pour conserver au moins 80 % de la variance ? Que perd-on en ne gardant que deux composantes pour *visualiser* ?

.....

.....

(c) Pourquoi la somme des valeurs propres vaut-elle exactement 6 ici ? Pourquoi faut-il standardiser avant une ACP ?

.....

.....