

Programmation Python

— Séance 6

NumPy

Dr. El Hadji Bassirou TOURÉ

Département de Mathématiques et Informatique, Faculté des Sciences et Techniques, Université Cheikh Anta Diop de Dakar

Objectifs de la séance


Contenu

On entre dans la **science des données** avec un exemple de **morphométrie** : des mesures relevées sur des spécimens de pinsons (bec, aile, masse). **numpy** fournit le **tableau** (**array**), sur lequel on calcule **sans boucle**. C'est l'outil sur lequel repose **pandas** (Séance 7) et, plus loin, le Machine Learning.

- **Le tableau** : **np.array**, types homogènes.
- **Vectorisation, agrégations, filtrage** sur une mesure (1D).
- **Tableaux 2D** et **axis** : la table complète spécimens $\times$ mesures.
- **Broadcasting** et **normalisation (z-score)** : le pont vers le ML.

L'entraînement se fait dans le **notebook**, avec une cellule « À vous » après chaque notion.

Deux idées centrales



La vectorisation (une opération agit sur chaque valeur, sans boucle) et l'argument `axis` (résumer la table par mesure ou par spécimen).

Le tableau NumPy

L'idée : un tableau pour le calcul

L'idée en une phrase

Un **tableau** NumPy est une collection de nombres **de même type**, conçue pour le calcul. On importe NumPy sous le nom `np`, et on crée un tableau avec `np.array(...)`. Ici, la **masse** (en g) de 6 spécimens de pinsons.

Le tableau ressemble à une liste, mais il autorise des opérations **globales** (sur tous les éléments à la fois) qui n'existent pas sur les listes.

Créer un tableau

```
import numpy as np  
  
masse = np.array([15, 16, 21, 22, 28, 27])  
print(masse)
```

Résultat →

```
[15 16 21 22 28 27]
```

`np` est le nom conventionnel de NumPy. Le tableau s'affiche sans virgules.

Des éléments de même type

```
bec = np.array([9.1, 8.0, 12.8])  
print(bec)
```

Résultat →

```
[ 9.1  8. 12.8]
```

Un tableau ne contient qu'un seul type. Comme les mesures de bec sont décimales, tout le tableau est **flottant** (le point après chaque nombre le signale).

La vectorisation

L'idée : calculer sans boucle

L'idée en une phrase

Une opération sur un tableau (+, *, une comparaison) s'applique à **chaque élément d'un seul coup**, sans boucle. C'est la **vectorisation** : un code plus court, plus lisible, et bien plus rapide.

Opérer sur tout le tableau

```
print(masse + 2)  
print(masse * 2)
```

Résultat →

[17 18 23 24 30 29]

[30 32 42 44 56 54]

`masse + 2` ajoute 2 à chaque masse ; `masse * 2` double chaque masse. Aucune boucle.

La boucle de la Séance 3, en une ligne

```
# Façon Séance 3 : une boucle
total = 0
for m in masse:
    total = total + m
print(total)

# Façon NumPy : vectorise
print(masse.sum())
```

Résultat →

129

129

Même résultat : NumPy remplace la boucle d'accumulation par un simple `.sum()`.

Piège — * agit élément par élément

Ce n'est pas un produit matriciel

`masse * masse` élève **chaque** masse au carré, case par case.

```
print(masse * masse)
```

Résultat →

[225 256 441 484 784 729]

$15^2 = 225$, $16^2 = 256$, etc. Le produit matriciel, lui, s'écrit avec `@` — hors de notre programme.

Les agrégations

Résumer un tableau en un nombre

```
print(masse.sum())  
print(masse.mean())  
print(masse.min())  
print(masse.max())
```

Résultat →

```
129  
21.5  
15  
28
```

La masse **moyenne** vaut 21.5 g. L'**écart-type** mesure la dispersion ; il tombe rarement rond, on l'arrondit :

```
print(round(masse.std(), 2))
```

```
4.92
```

Le filtrage booléen

Sélectionner des spécimens : un masque

```
print(masse >= 20)
print(masse[masse >= 20])
print((masse >= 20).sum())
```

Résultat →

```
[False False  True  True  True  True]
[21 22 28 27]
4
```

La comparaison produit un **masque** de `True/False` ; placé entre crochets, il **sélectionne** les spécimens d'au moins 20 g ; `.sum()` sur un masque les **compte** (4, sans doute les plus grandes espèces).

Les tableaux 2D

L'idée : la table complète

L'idée en une phrase

On a mesuré **4 caractères** par spécimen. On les range dans un tableau **2D** : une **ligne** par spécimen, une **colonne** par mesure (longueur de bec, hauteur de bec, aile, masse). `shape` donne le format (`spécimens, mesures`).

Créer un tableau 2D

```
# colonnes : bec_long, bec_haut, aile, masse
X = np.array([[ 9.1,  8.0, 67, 15],
              [ 9.4,  8.3, 68, 16],
              [12.8, 10.5, 74, 21],
              [13.2, 10.9, 75, 22],
              [16.1, 14.2, 80, 28],
              [15.7, 13.8, 79, 27]])

print(X)
print(X.shape)
```

Résultat →

```
[[ 9.1  8.  67. 15. ]
 [ 9.4  8.3 68. 16. ]
 [12.8 10.5 74. 21. ]
 [13.2 10.9 75. 22. ]
 [16.1 14.2 80. 28. ]
 [15.7 13.8 79. 27. ]]
(6, 4)
```

Accéder aux spécimens et aux mesures

```
print(X[0, 0])  
print(X[0])  
print(X[:, 0])  
print(X[:, 3])
```

Résultat →

```
9.1  
[ 9.1  8.  67. 15. ]  
[ 9.1  9.4 12.8 13.2 16.1 15.7]  
[15. 16. 21. 22. 28. 27.]
```

[spécimen, mesure] pour une valeur ; `X[0]` un spécimen entier ; `X[:, 0]` la colonne des becs ; `X[:, 3]` celle des masses (le `:` veut dire « tous les spécimens »).

L'argument axis

L'idée : dans quel sens résumer

L'idée en une phrase

Sur un tableau 2D, une agrégation se fait **par colonne** ou **par ligne**, selon `axis`. `axis=0` descend les **colonnes** : une valeur par **mesure**. `axis=1` parcourt les **lignes** : une valeur par **spécimen**.

Moyenne par mesure, moyenne par spécimen

```
print(X.mean(axis=0).round(2))  
print(X.mean(axis=1).round(2))
```

Résultat →

```
[12.72 10.95 73.83 21.5 ]  
[24.78 25.42 29.58 30.28 34.58 33.88]
```

axis=0 : moyenne de **chaque mesure** (bec 12.72 mm, aile 73.83 mm, masse 21.5 g) — ce qui a un sens. **axis=1** mélange des unités (mm et g) : correct, mais **peu parlant** — d'où la normalisation, juste après.

Broadcasting et normalisation

L'idée : opérer entre un tableau et un vecteur

L'idée en une phrase

Le **broadcasting** permet d'opérer entre un tableau 2D et un vecteur : le vecteur est appliqué à chaque ligne. Ici, on retire à **chaque mesure** sa propre moyenne (calculée par `axis=0`).

Retirer à chaque mesure sa moyenne

```
print((X - X.mean(axis=0)).round(2))
```

Résultat →

```
[[-3.62 -2.95 -6.83 -6.5 ]  
 [-3.32 -2.65 -5.83 -5.5 ]  
 [ 0.08 -0.45  0.17 -0.5 ]  
 [ 0.48 -0.05  1.17  0.5 ]  
 [ 3.38  3.25  6.17  6.5 ]  
 [ 2.98  2.85  5.17  5.5 ]]
```

Le vecteur des moyennes par colonne est soustrait à **chaque ligne** : NumPy l'étend automatiquement à toute la hauteur du tableau.

Normaliser (z-score) : le pont vers le ML

Des unités différentes

Bec et aile en mm, masse en g : pour comparer les mesures, on **normalise** chaque colonne — retirer la moyenne, diviser par l'écart-type.

```
X_reduit = (X - X.mean(axis=0)) / X.std(axis=0)
print(X_reduit.std(axis=0).round(2))
```

Résultat →

```
[1. 1. 1. 1.]
```

Après normalisation, **chaque mesure** a une moyenne de 0 et un écart-type de 1 : toutes sont ramenées à une échelle commune, quelle que soit leur unité. Ce geste est **systématique** en morphométrie comme avant d'entraîner un modèle.

Synthèse

Pièges fréquents

- * n'est **pas** le produit matriciel : il multiplie **élément par élément**.
- Le sens de `axis` : `axis=0` **par mesure** (colonne), `axis=1` **par spécimen** (ligne).
- **Mélanger des unités** : moyenner des mesures d'unités différentes (mm et g) n'a pas de sens ; on **normalise** d'abord.
- Un tableau a des **types homogènes** : mélanger entiers et flottants donne des flottants.

À retenir — Séance 6

L'essentiel

Créer : `import numpy as np` puis `np.array(...)` ; éléments de **même type**.

Vectorisation : une opération s'applique à **tout le tableau**, sans boucle.

Agrégations : `.sum()`, `.mean()`, `.std()`, `.min()`, `.max()`.

Filtrage : masque `tableau >= v`, puis `tableau[masque]`.

2D : `shape` donne (`spécimens`, `mesures`) ; accès `[i, j]`, `[:, j]` (mesure), `[i, :]` (spécimen).

axis : `axis=0` par mesure, `axis=1` par spécimen.

Normalisation (z-score) : `(X - X.mean(axis=0)) / X.std(axis=0)` ramène chaque mesure à une moyenne de 0 et un écart-type de 1.

Prochaine séance

Séance 7 — pandas

NumPy calcule sur des tableaux de nombres. `pandas`, bâti sur NumPy, ajoute des **colonnes nommées** et une colonne `espece` : le **DataFrame**, la table de données de la bio-informatique. On y manipulera la table complète des pinsons — tris, groupes par espèce, valeurs manquantes.

À faire d'ici là : refaire les cellules « À vous » du notebook de la séance.

Références

- Harris, C. et al. — *Array programming with NumPy*, Nature, 2020.
- VanderPlas, J. — *Python Data Science Handbook*, 2e éd., O'Reilly, 2023.
- McKinney, W. — *Python for Data Analysis*, 3e éd., O'Reilly, 2022.
- NumPy — *NumPy: the absolute basics for beginners* (documentation), 2024.

Ressources de la séance

- **Notebook** · [TP 6 — NumPy](#) (16 Ko)