

Programmation Python

# Séance 8 — Visualiser et faire le pont

**Dr. El Hadji Bassirou TOURÉ**

Département de Mathématiques et Informatique, Faculté des Sciences et Techniques, Université Cheikh Anta Diop de Dakar



---

<https://elbachir67.github.io/cours/programmation-python/chapitres/08-visualiser-et-faire-le-pont.html>

Version du 24 septembre 2026



Version en ligne

# Programmation Python

## — Séance 8

Visualiser et faire le pont

Dr. El Hadji Bassirou TOURÉ

Département de Mathématiques et Informatique, Faculté des Sciences et Techniques, Université Cheikh Anta Diop de Dakar

# Objectifs de la séance

## De quoi parle cette séance

Jusqu'ici, on a appris à **calculer** sur des données. Aujourd'hui, on apprend à les **regarder** — et à comprendre ce qu'un graphique dit, ou ne dit pas. C'est la dernière étape avant le Machine Learning.

- **Pourquoi** visualiser : ce qu'une moyenne ne montre pas.
- **Comment lire** un graphique : ses éléments, ce qu'on y cherche.
- **Lequel choisir** : histogramme, barres ou nuage de points.
- **Le pont vers le ML** : reconnaître un fruit à partir de ses mesures.

# Le jeu de données : 30 fruits du marché

## Trois fruits, trois mesures

On a pesé et mesuré 10 **mangues**, 10 **bananes** et 10 **oranges**. Pour chaque fruit : sa **masse** (g), sa **longueur** (cm) et son **taux de sucre** (%).

|   | fruit  | masse | longueur | sucres |
|---|--------|-------|----------|--------|
| 0 | mangue | 301   | 10.3     | 14.7   |
| 1 | banane | 137   | 18.4     | 11.1   |
| 2 | orange | 201   | 8.1      | 9.2    |

**Une ligne = un fruit. Une colonne = une mesure.** C'est la forme de toute table de données, et celle que le Machine Learning attend.

# Pourquoi visualiser


# Le problème : une moyenne ne dit pas tout

## Une question simple

Deux paniers de fruits ont **exactement la même masse moyenne** : 200 g. Contiennent-ils la même chose ?

Avec les seuls chiffres, impossible de répondre : la moyenne est identique. Il faut **regarder la répartition** — c'est-à-dire compter combien de fruits se trouvent dans chaque tranche de masse.

# La réponse, en un coup d'œil



Deux paniers de masse moyenne identique (200 g), mais de composition totalement différente.

# Ce que cette figure nous apprend

- **Panier A** : tous les fruits pèsent autour de 200 g. La moyenne **représente bien** le panier — ce sont sans doute dix oranges.
- **Panier B** : aucun fruit ne pèse 200 g ! Il y a des fruits légers ( $\approx 120$  g) et des fruits lourds ( $\approx 280$  g). La moyenne ne correspond à **aucun** fruit réel.

## À retenir

Une moyenne résume, mais elle **cache la forme** des données. Deux jeux très différents peuvent avoir la même moyenne : **il faut regarder avant de conclure**.

# Ce qu'un graphique permet de voir

- **La répartition** : les valeurs sont-elles groupées, étalées, ou séparées en plusieurs paquets ?
- **Les groupes** : y a-t-il des familles distinctes dans les données ?
- **Les liens** : quand une mesure augmente, qu'arrive-t-il à une autre ?
- **Les anomalies** : une valeur aberrante saute aux yeux sur un graphique, jamais dans un tableau.

C'est pourquoi visualiser est le **premier réflexe** de tout travail sur des données — avant le moindre calcul savant.

# Lire un graphique

# Les éléments d'un graphique



Tout graphique se lit de la même façon : un titre, deux axes légendés, et des formes qui portent l'information.

# Un graphique sans légende ne veut rien dire

## L'erreur la plus fréquente


Un graphique sans titre ni unités est **illisible** : « 300 » de quoi ? des grammes, des francs, des fruits ?

- `title` : ce que l'on regarde.
- `xlabel` et `ylabel` : ce que représente chaque axe, **avec l'unité**.
- `legend` : à quoi correspond chaque couleur, dès qu'il y a des groupes.

Trois lignes de code, mais elles font la différence entre une image et une **information**.

# Choisir le bon graphique

# Le graphique dépend de la question posée



On ne choisit pas un graphique parce qu'il est joli, mais parce qu'il répond à la question que l'on se pose.

# Trois questions, trois graphiques

- « **Comment se répartissent les masses ?** » — une seule mesure, on veut sa forme : **histogramme**.
- « **Quel fruit est le plus lourd en moyenne ?** » — une mesure comparée entre groupes : **diagramme en barres**.
- « **Les fruits longs sont-ils les plus lourds ?** » — deux mesures ensemble : **nuage de points**.

## La bonne habitude

Formuler la question **en français d'abord**. Le choix du graphique en découle, et le code n'est plus qu'une formalité.

# L'histogramme

# Comprendre l'histogramme

## L'idée en une phrase

L'histogramme découpe l'axe d'une mesure en **tranches** de même largeur, puis compte combien d'individus tombent dans chaque tranche. La hauteur d'une barre est donc un **effectif**.


## Une image

Comme si l'on rangeait les fruits dans des casiers étiquetés « 100–120 g », « 120–140 g »... puis qu'on comptait les fruits de chaque casier.

Attention : les barres se touchent, car la mesure est **continue** — c'est ce qui le distingue du diagramme en barres.

# L'histogramme en pratique

```
plt.hist(df["masse"], bins=range(100, 360, 20))  
plt.xlabel("masse (g)")  
plt.ylabel("nombre de fruits")  
plt.title("Distribution des masses")
```



# Lire cet histogramme

- L'axe des x porte la **masse** ; l'axe des y, le **nombre de fruits**.
- On distingue **trois amas** : vers 120 g, vers 200 g et vers 300 g.
- Entre ces amas, presque **aucun fruit** : les groupes sont bien séparés.

## L'interprétation

Trois amas = trois familles de fruits. Ce sont les **bananes**, les **oranges** et les **mangues** — alors que la colonne **fruit** n'a jamais été utilisée pour tracer ce graphique.

# Le rôle des tranches (**bins**)

- Des tranches **trop larges** lissent tout : les trois amas disparaissent en une seule barre.
- Des tranches **trop fines** font apparaître du bruit : chaque fruit devient sa propre barre.
- On ajuste jusqu'à voir la **structure** sans le bruit — ici, des tranches de 20 g.

C'est un **réglage**, pas une vérité : changer les tranches change ce que l'on voit.  
Raison de plus pour toujours indiquer ses choix.

# Le diagramme en barres

# Comprendre le diagramme en barres

## L'idée en une phrase

Le diagramme en barres compare **une valeur entre des groupes** : une barre par groupe, dont la hauteur est la valeur. Il part toujours d'une **agrégation** — une moyenne, une somme, un comptage.

La démarche est en deux temps, déjà vus en Séance 7 :

**Regrouper puis résumer** : `groupby("fruit")["masse"].mean()`.

**Tracer** le résultat : une barre par fruit.

# Le diagramme en barres en pratique

```
masse_moy = df.groupby("fruit")["masse"].mean()  
plt.bar(masse_moy.index, masse_moy.values)  
plt.ylabel("masse moyenne (g)")  
plt.title("Masse moyenne par fruit")
```



# Lire ce diagramme

## Les chiffres

Mangue : **304 g** en moyenne. Orange : **204 g**. Banane : **119 g**.

- La comparaison est **immédiate** : une mangue pèse environ deux fois et demie une banane.
- Mais attention : ce graphique montre des **moyennes**. Il ne dit rien de la dispersion à l'intérieur de chaque groupe.

C'est le complément de l'histogramme, pas son remplaçant : l'un montre la **forme**, l'autre compare des **résumés**.

# Le nuage de points

# Comprendre le nuage de points

## L'idée en une phrase

Le nuage de points place chaque individu selon **deux** mesures : une en abscisse, une en ordonnée. Chaque point est un fruit ; sa position résume ses deux mesures.

On y cherche deux choses :

- un **lien** : quand la longueur augmente, la masse augmente-t-elle aussi ?
- des **groupes** : les points forment-ils des paquets séparés ?

En **colorant par catégorie**, on répond aux deux questions d'un seul regard.

# Le nuage révèle les fruits



Chaque point est un fruit, placé selon sa longueur et sa masse, coloré selon son type.

Trois **amas nettement séparés**, sans le moindre chevauchement.

# Lire ce nuage, groupe par groupe

- La **banane** : longue (17–20 cm) mais légère ( $\approx 120$  g) — en bas à droite.
- La **mangue** : courte (10–12 cm) et lourde ( $\approx 300$  g) — en haut au milieu.
- L'**orange** : la plus courte (7–9 cm), de masse moyenne ( $\approx 200$  g) — à gauche.

## Le point décisif

Les trois groupes ne se touchent pas. Autrement dit : **connaître la longueur et la masse suffit à identifier le fruit** — sans le voir. C'est exactement ce que le Machine Learning va automatiser.

# Une mini-EDA

# La démarche d'analyse exploratoire

## Quatre gestes, toujours les mêmes

L'**analyse exploratoire** (EDA) n'est pas une technique, c'est une **méthode** : comprendre les données avant de modéliser.

**Charger** : lire le fichier, vérifier `shape` — combien de lignes, de colonnes ?

**Décrire** : `describe`, `value_counts` — quelles valeurs, quels effectifs, des manques ?

**Tracer** : histogramme, barres, nuage — quelle forme, quels groupes ?

**Observer** : formuler en français ce que l'on a compris.

# Le profil de chaque fruit

```
print(df.groupby("fruit")[["masse", "longueur", "sucre"]].mean().round(1))
```

**Résultat** →

|        | masse | longueur | sucré |
|--------|-------|----------|-------|
| fruit  |       |          |       |
| banane | 119.0 | 19.0     | 11.8  |
| mangue | 304.4 | 10.9     | 14.0  |
| orange | 204.3 | 8.2      | 9.0   |

Trois lignes, trois colonnes : le **portrait chiffré** de chaque fruit.

# L'étape « observer » : que dit ce tableau ?

- La **mangue** est la plus lourde (304 g) et la plus sucrée (14 %).
- La **banane** est de loin la plus longue (19 cm) et la plus légère.
- L'**orange** est la moins sucrée (9 %) et la plus courte.

## Le point clé

**Chaque mesure sépare les fruits, à sa manière.** La masse distingue bien la mangue ; la longueur, la banane ; le sucre, l'orange. Un modèle exploitera les trois **ensemble**.

# Le pont vers le ML

# L'idée du Machine Learning, en une image

## Ce que l'on vient de faire à la main

En regardant le nuage de points, **vous** avez appris à reconnaître un fruit : « long et léger → banane ». Le Machine Learning, c'est confier cet apprentissage à un programme.

Pour cela, on lui donne les données sous une forme précise :

- **x** — ce que l'on **observe** : les mesures (masse, longueur, sucre).
- **y** — ce que l'on veut **prédire** : le nom du fruit.

# De la table aux objets $X$ et $y$

| X (les mesures) |          |        | y (a predire) |
|-----------------|----------|--------|---------------|
| masse           | longueur | sucres | fruit         |
| 301             | 10.3     | 14.7   | mangue        |
| 137             | 18.4     | 11.1   | banane        |
| 201             | 8.1      | 9.2    | orange        |

*Le modele apprend le lien  $X \rightarrow y$  : reconnaitre le fruit a partir de ses mesures.*

Les colonnes de mesures forment  $X$  ; la colonne à prédire forme  $y$ .

Une ligne de  $X$  et la valeur de  $y$  en face décrivent **le même fruit**.

# Construire $X$ et $y$

```
X = df[["masse", "longueur", "sucre"]].values
y = df["fruit"].values
print("X shape :", X.shape)
print("y shape :", y.shape)
```

## Résultat →

```
X shape : (30, 3)
y shape : (30,)
```

$X$  est une **matrice** (30, 3) : 30 fruits en lignes, 3 mesures en colonnes.  $y$  est un **vecteur** (30, ) : un nom par fruit. Les deux ont forcément **le même nombre de lignes**.

# La suite, dans le cours de Machine Learning

Sous cette forme, `X` et `y` sont exactement ce qu'attend scikit-learn. Ce code n'est pas exécuté ici — il montre où l'on va :

```
modele = DecisionTreeClassifier()  
modele.fit(X, y)           # il APPREND le lien X -> y  
modele.predict([[300, 11, 14]]) # 300 g, 11 cm, 14 % : mangue ?
```

## Deux mots pour finir

`fit` : le modèle **apprend** sur des fruits déjà étiquetés. `predict` : il **décide** pour un fruit nouveau. Tout le cours de Machine Learning consiste à comprendre ce qui se passe entre les deux.

# Synthèse

# Pièges fréquents

- **Conclure sur une moyenne** sans avoir regardé la répartition (souvenez-vous des deux paniers).
- **Oublier les légendes** : un graphique sans titre ni unités n'informe personne.
- **Choisir le graphique avant la question** : c'est la question qui commande.
- **Confondre les rôles** :  $x$  contient ce que l'on mesure,  $y$  ce que l'on cherche à prédire.

# À retenir — Séance 8

## L'essentiel

**Pourquoi** : une moyenne cache la forme des données ; un graphique la révèle.

**Lequel** : une mesure → histogramme ; une mesure par groupe → barres ; deux mesures → nuage de points.

**Comment lire** : titre, axes légendés avec unités, légende des couleurs ; puis chercher formes, groupes, liens.

**Mini-EDA** : charger → décrire → tracer → observer.

**Pont ML** :  $X$  (ce que l'on mesure) et  $y$  (ce que l'on prédit) ; **fit** pour apprendre, **predict** pour décider.

# Bilan du cours

## Le chemin parcouru

Des valeurs et des types (S1) aux structures (S2), au contrôle du flux (S3), aux fonctions (S4), aux objets (S5) ; puis à NumPy (S6), pandas (S7) et à la visualisation (S8).

Vous savez désormais **charger, explorer, résumer et représenter** des données — et vous comprenez ce qu'un modèle attend. Le cours de **Machine Learning** peut commencer.

# Références

- Hunter, J. D. — *Matplotlib: A 2D Graphics Environment*, CiSE, 2007.
- VanderPlas, J. — *Python Data Science Handbook*, 2e éd., O'Reilly, 2023.
- McKinney, W. — *Python for Data Analysis*, 3e éd., O'Reilly, 2022.
- Tufte, E. — *The Visual Display of Quantitative Information*, 2e éd., 2001.

# Ressources de la séance

- **Notebook** · [TP 8 — Visualiser et faire le pont](#) (116 Ko)